

Einführung in Data Science

Überblick & Grundbegriffe



Heute

1. Was ist Data Science?
2. Organisatorisches


1. Was ist Data Science?

Überblick & Grundbegriffe

1. Was ist Data Science?

Was verstehen Sie unter Data Science?

- Ziel: Extraktion von Wissen aus Daten
- Verwandte Begriffe
 - Maschinelles Lernen
 - Künstliche Intelligenz
 - Data Engineering
 - Klassifizierung
 - Regression
 - Clustering
 - ...



Überblick & Grundbegriffe

1. Was ist Data Science?

Was für Wissen können wir gewinnen?

The screenshot shows a Google search for 'Aachen'. The search bar at the top contains the word 'Aachen'. Below the search bar, the first result is from 'Aachen.de' with the URL 'https://www.aachen.de'. The title of the result is 'www.aachen.de - Aachen - Willkommen im Stadtportal'. Below the title, there is a snippet of text: 'Neues aus Aachen · Stadt Aachen bringt „Haus der Neugier“ auf den Weg · So hat Aachen gewählt · AachenPanel: eine Umfrageplattform für alle Aachener*innen · Die ...'. Below this snippet, there are several links: 'Das ist Aachen', 'Serviceportal', 'Aktuelle Pressemitteilungen', and 'Aachen Profil'. The second result is from 'Wikipedia' with the URL 'https://de.wikipedia.org/wiki/Aachen'. The title of the result is 'Aachen'. Below the title, there is a snippet of text: '1890 überschritt Aachen erstmals die Einwohnerzahl von 100.000 und ist seitdem die westlichste deutsche Großstadt. Aachen grenzt an die Niederlande und Belgien. Städteregion Aachen · Brand (Aachen) · Walheim (Aachen) · RWTH Aachen'. Below this snippet, there is a small image of Aachen. To the right of the search results, there is an 'About' panel. The panel contains the following text: 'Aachen is a spa city near Germany's borders with Belgium and the Netherlands. Aachen Cathedral was founded around 800 A.D. and a Gothic chancel was added later. Its Domschatzkammer (treasury) has medieval artifacts including the shrine of Charlemagne, who was buried here in 814 A.D. Nearby is the baroque town hall, Aachener Rathaus, with 19th-century frescoes. Sulfurous water fills the fountains of Elisenbrunnen. — Google'. Below this text, there are several facts: 'Area: 160.8 km²', 'Postal codes: 52062–52080', 'Admin. region: Cologne', 'Dialling codes: 0241 / 02405 / 02407 / 02408', 'District: Aachen', and 'Elevation: 173 m (568 ft)'. At the bottom right of the panel, there is a 'Feedback' link.

Google

Aachen

Aachen.de
https://www.aachen.de · Translate this page

www.aachen.de - Aachen - Willkommen im Stadtportal

Neues aus Aachen · Stadt Aachen bringt „Haus der Neugier“ auf den Weg · So hat Aachen gewählt · AachenPanel: eine Umfrageplattform für alle Aachener*innen · Die ...

Das ist Aachen · Serviceportal · Aktuelle Pressemitteilungen · Aachen Profil

Wikipedia
https://de.wikipedia.org/wiki/Aachen · Translate this page

Aachen

1890 überschritt Aachen erstmals die Einwohnerzahl von 100.000 und ist seitdem die westlichste deutsche Großstadt. Aachen grenzt an die Niederlande und Belgien. Städteregion Aachen · Brand (Aachen) · Walheim (Aachen) · RWTH Aachen

People also ask

Was gibt es besonderes in Aachen?

About

Aachen is a spa city near Germany's borders with Belgium and the Netherlands. Aachen Cathedral was founded around 800 A.D. and a Gothic chancel was added later. Its Domschatzkammer (treasury) has medieval artifacts including the shrine of Charlemagne, who was buried here in 814 A.D. Nearby is the baroque town hall, Aachener Rathaus, with 19th-century frescoes. Sulfurous water fills the fountains of Elisenbrunnen. — Google

Area: 160.8 km²

Postal codes: 52062–52080

Admin. region: Cologne

Dialling codes: 0241 / 02405 / 02407 / 02408

District: Aachen

Elevation: 173 m (568 ft)

Feedback

Quelle: Google

Überblick & Grundbegriffe

1. Was ist Data Science?

Was für Wissen können wir gewinnen?

The screenshot shows the Amazon Germany homepage. At the top, the Amazon logo is on the left, and the location is set to 'Deutschland'. The search bar contains 'Muse S Gen 2'. Below the search bar, there are links for 'Seitenanfang', 'Info zu diesem Artikel', 'Ähnlich', 'Produktinformationen', 'Fragen', and 'Rezensionen'. The main section is titled 'Bestseller in diese Kategorie' and displays a row of seven products: Band-Aid Flexible Gewebe-Klebebanden, LHKNL Stirnlampe, HotHands Handwärmer, Nexcare Starker Halt, Amazon Basics 1,27 cm extra dicke Yogamatte, Springsail, and Penn Championship Tennisbälle. Each product has a star rating and a 'Bestseller Nr. 1' badge.

Kunden, die Artikel in deinem Browserverlauf angesehen haben, haben auch angesehen

Kunden, die Artikel in deinem Browserverlauf angesehen haben, haben auch angesehen


The screenshot shows a row of seven product recommendations for the Muse S Gen 2. The products are: Biosensing Meditation Headband - Real-Time, NeuroMyst Pro tDCS Device Kit - Dual DC + AC, MUSE 2 Schutzkissen - Das Gehirn-Sensing-Elektroden-Set, tDCS-Gerät TheBrainDriver v2. tDCS, Brain spa, Schlaflosigkeit, tDCS-Gerät TheBrainDriver v2. tDCS, and Reflect Orb: Smart Tracker für bessere psychische Gesundheit. Each product has a star rating and a 'Bestseller Nr. 1' badge.

Quelle: Amazon

Überblick & Grundbegriffe

1. Was ist Data Science?

Was für Wissen können wir gewinnen?



Textgenerierung



Bildgenerierung

Brain-Computer Interfaces




Quelle: Wikipedia, OpenBCI

Überblick & Grundbegriffe


1. Was ist Data Science?

Beispiel – Brain-Computer Interfaces

- Ziel: Steuerung eines Spiels durch echte und **vorgestellte** Bewegungen



https://www.youtube.com/watch?v=Pc_I0DKV6CQ



Quelle: InteraXon Inc., Neurosity Inc., SNAP GmbH

Überblick & Grundbegriffe


1. Was ist Data Science?

Data Scientist

Daten analysieren, visualisieren, interpretieren, modellieren, Zusammenhänge erkennen



Erkenntnisse
Vorhersagen



Data Engineer

Daten sammeln, speichern, bereinigen, zusammenführen, bereitstellen, ETL




IT-Infrastruktur
Daten-Schnittstellen

Überblick & Grundbegriffe

1. Was ist Data Science?


Bezeichnungen in der Wirtschaft & Industrie



Überblick & Grundbegriffe

1. Was ist Data Science?

Datenbeschaffung und -aufbereitung



➤ Datenbeschaffung

- Oft: unstrukturierte, heterogene Quellen
- z.B. Dateien, Datenbanken, APIs, Webservices, Web scraping, öffentliche Datensätze

➤ Datenbereinigung/-transformation

- z.B. Anonymisierung, Beseitigung von Fehlern, Duplikaten und fehlenden Werten, Umwandlung in geeignetes Format

Typisch für Datenaufbereitung

- Kette von Arbeitsschritten (Pipelines)
- Domänenspezifisch


Wichtige Tools

- SQL, NoSQL
- Python: NumPy, Pandas
- APIs, Web Scraping


Überblick & Grundbegriffe

1. Was ist Data Science?

Explorative Analyse




- Visualisierung
- Deskriptive Statistik
- Statistisches Testen
- Schätzer
- Clustering
- ...
- Wichtige Tools: Python, R, MATLAB



Überblick & Grundbegriffe


1. Was ist Data Science?

Explorative Analyse



➤ Beispiel


- Vermutung: Pflanzen wachsen bei hohen Temperaturen besser
- Teste $H_0: \text{Corr}(\text{Wachstum}, \text{Temperatur}) > 0.5$
- H_0 wird verworfen: hohe Temperaturen schaden den Pflanzen
- Vermutung: Es gibt eine optimale Temperatur
- Teste H_0 : ...
- ...



Überblick & Grundbegriffe

1. Was ist Data Science?

Feature Engineering




- Features: Merkmale der Daten
- Feature Engineering: Prozess, Features zu finden, die die Daten gut* beschreiben
- Nutze Erkenntnisse aus explorativer Analyse und Domänenexpertise
- Wichtige Tools: Statistik, Python (NumPy, Pandas)

*gut im Hinblick auf Fragestellung


Überblick & Grundbegriffe

1. Was ist Data Science?




Feature Engineering

➤ Beispiel (MNIST Datensatz)



- Ziel: Automatische Erkennung der Ziffern
- Datensatz: 60 000 Ziffern
- Ziffern: 28x28 Pixel



- Wie viel Fläche ist bedeckt?
- Ist die Ziffer symmetrisch?



Features

Schwärze:


$$x_1 = \sum_{i=1}^{28} \sum_{j=1}^{28} p_{i,j}$$

Asymmetrie:

$$x_2 = \sum_{i=1}^{28} \sum_{j=1}^{28} |p_{i,j} - p_{-i,j}|$$

Überblick & Grundbegriffe

1. Was ist Data Science?



Feature Engineering

- Feature Engineering schließt Darstellung der Daten ein
 - Features sind nicht zwangsläufig Zusammenfassungen!
 - Warum ist das wichtig?

Beispiel: Gesucht ist eine Funktion $f: \mathbb{N} \rightarrow \{0,1\}$ mit $f(k) = \begin{cases} 0, & \text{falls } k \text{ gerade} \\ 1, & \text{falls } k \text{ ungerade} \end{cases}$

- z.B. $f(4) = 0, f(3) = 1$

Lösung 1

$$f(k) = \frac{\cos(\pi k) + 1}{2}$$


Lösung 2

1. Konvertierung in Binärdarstellung: $k_{10} \rightarrow k_2$
2. Abbildung auf letzte Ziffer: $k_2 \rightarrow k_2^{(0)}$

Überblick & Grundbegriffe

1. Was ist Data Science?

Feature Engineering



- Die Repräsentation von Daten spielt eine Rolle!

Test


Lernen Sie die folgende Codierung auswendig

Quelle: <https://home.work.caltech.edu/telecourse.html>

Überblick & Grundbegriffe

1. Was ist Data Science?

Modellierung



Unterschiedliche Fragestellungen

Überwachtes Lernen (supervised learning)

- Gegeben: Daten $(x_1, y_1), \dots, (x_n, y_n)$
- Gesucht: $f: X \rightarrow Y$ mit $f(x) \approx y$
- Beispiele:
 - Klassifizierung
 - Regression

Unüberwachtes Lernen (unsupervised learning)

- Gegeben: Daten $x_1, \dots, x_n$
- Gesucht: $f: X \rightarrow ?$
- Beispiele:
 - Clustering
 - Dimensionsreduktion
 - Ausreißerdetektion
 - Datenaugmentierung




Bestärkendes Lernen (reinforcement learning)

- Gegeben: Daten $(s_1, a_1, r_1), \dots, (s_n, a_n, r_n)$
- Gesucht: $\pi: S \times A \rightarrow [0, 1]$
- Anwendungen:
 - Roboter
 - Computerspiele




Überblick & Grundbegriffe

1. Was ist Data Science?


Modellierung



$$f = -1$$



$$f = +1$$



$$f = ?$$


Quelle: <https://home.work.caltech.edu/telecourse.html>

Überblick & Grundbegriffe

1. Was ist Data Science?

Modellierung

➤ Beispiel (MNIST Datensatz)





- Ziel: Automatische Erkennung der Ziffern

Modell: $f(x_1) = m \cdot x_1 + c$

Parameter: m, c

Entscheidungsregel: $\begin{cases} 1, \text{ falls } x_2 < f(x_1) \\ 5, \text{ falls } x_2 \geq f(x_1) \end{cases}$

- Wie wählen wir m und c ?



Überblick & Grundbegriffe

1. Was ist Data Science?

Überwachtes Lernen (Modul: Maschinelles Lernen)

➤ Lineare Modelle

- Lineare Regression
- Logistische Regression (Klassifizierung!)
- LASSO
- Ridge Regression
- ElasticNet

➤ Baumbasierte Modelle

- Entscheidungsbäume
- Random Forests

➤ Nächste Nachbarn


- k-nearest neighbors
- Kernregression

➤ Neuronale Netze



- MLP, CNN, RNN, LSTM, SNN, Transformer, KAN

Überblick & Grundbegriffe

1. Was ist Data Science?




Beispiel – BCI-Workflow



Überblick & Grundbegriffe



1. Was ist Data Science?



Beispiel – BCI-Workflow

EEG (Elektroenzephalografie)


- Tragbar
- Nicht-invasiv
- Preis: ab 300€
- Elektroden messen elektrische Aktivität auf der Kopfhaut:
 - Gelelektroden
 - Trockenelektroden



Quelle: InteraXon Inc., Neurosity Inc., SNAP GmbH

Überblick & Grundbegriffe

1. Was ist Data Science?





Beispiel – BCI-Workflow

1 Sekunde, 250 Hz



30 Sekunden, 250 Hz




Was fällt Ihnen auf?

Rauschen!

Überblick & Grundbegriffe

1. Was ist Data Science?




Beispiel – BCI-Workflow

Rauschen


➤ 50 Hz Rauschen

- Woher?




➤ Langzeit Drift

- Woher?




➤ Peaks

- Woher?



Überblick & Grundbegriffe

1. Was ist Data Science?




Beispiel – BCI-Workflow



➤ Bandpass-Filter

- Zerlege Signal in „Schwingungen“ unterschiedlicher Frequenzen
- Filter Daten aus bestimmten Frequenzbereichen heraus
- Häufig: 5 – 40 Hz

➤ Vorher




➤ Nachher



Überblick & Grundbegriffe


1. Was ist Data Science?



Beispiel – BCI-Workflow

Modellierung

- Wie werden aus EEG-Daten Vorhersagen?
- Manuelle Features (z.B. Aktivität in bestimmten Frequenzbändern)
- Automatische Features (z.B. neuronale Netze)
- Einfacher:
 - Augenbewegungen
 - Berechne Abstand zwischen Beobachtung und Trend
 - Falls Abstand groß: Blinzeln



Überblick & Grundbegriffe

1. Was ist Data Science?

Neue Rolle

- An die Seite des Programmierers tritt der Data Scientist

schreibt mittels
Anweisungen, was der
Computer erledigen soll

zeigt mittels Datensätzen,
was der Computer
erledigen soll

Aufgaben

- Datensätze erschließen, kuratieren
- Verzerrungen (Bias) in Datensätzen untersuchen
- Daten bereinigen
- Modelle erstellen
- Modelle und ihre Vorhersagen verstehen
- ...

Überblick & Grundbegriffe

1. Was ist Data Science?

Neue Rolle

“Our relationship to computers has changed. Instead of programming them, we now show them [what to do].

That’s a completely different way of using computers.

Computer science departments are built around the idea of programming computers, and they don't understand that showing computers is going to be as big as programming computers.

So, they don't understand that half the people in the department should be people who get computers to do things by showing them”




Geoffrey Hinton
„Godfather of AI“
Nobelpreisträger
Prof. em. Universität Toronto
Ehemals: Google

Quelle: <https://www.youtube.com/watch?v=-eyhCTvrEtE>


Überblick & Grundbegriffe

1. Was ist Data Science?

Klassische Software



Maschinelles Lernen



2. Organisatorisches

Überblick & Grundbegriffe

2. Organisatorisches

Inhalte

- ➔ 1. Überblick & Grundbegriffe
- 2. Einführung in Python (NumPy und Pandas)
- 3. Eindimensionale EDA und Visualisierungen
- 4. Visualisierungen und mehrdimensionale EDA
- 5. Mehrdimensionale EDA
- 6. Dimensionsreduktion: PCA
- 7. Dimensionsreduktion: MDS, Isomap
- 8. Clustering: Algorithmen
- 9. Clustering: Validierung
- 10. Probeklausur
- 11. Feature Engineering, datengetriebene Modelle
- 12. Datengetriebene Modelle
- 13. Zeitreihen

Überblick &
Grundlagen

Explorative
(Daten-)
Analyse (EDA)

Feature
Engineering &
Modellierung

Überblick & Grundbegriffe

2. Organisatorisches

Lernziele

- Sie können...
 - ... Data Science Projekte selbstständig durchführen,
 - ... Methoden zur Erschließung und Aufbereitung von Daten sowie zu ihrer explorativen Analyse und Modellierung anwenden,
 - ... die Ergebnisse Ihrer Untersuchungen diskutieren und beurteilen.
- Bei der Durchführung von Data Science Projekten treffen die Studierenden Entscheidungen, die auf den Ergebnissen ihrer hypothesengetriebenen Untersuchungen basieren.

Überblick & Grundbegriffe

2. Organisatorisches

Vorlesung:	2 SWS	}	45 Zeitstunden	(=3h pro Woche)
Übung:	2 SWS			

Vor- und Nachbereitung:	50 Zeitstunden	}	(≈7h pro Woche)
Hausarbeiten u.a.:	55 Zeitstunden		

Gesamt: 5 ECTS

150 Zeitstunden

Überblick & Grundbegriffe

2. Organisatorisches

Ablauf

- Vorlesung: 12:30 – 14:00
- Übung: 14:00 – 15:30
 - Dienen zur Vertiefung des Lernstoffs
 - Zusammenarbeit in Gruppen
- Prüfung
 - Elektronische Klausur
 - Termin: Wird noch bekannt gegeben
 - 75 min
- Kontakt
 - Bevorzugt: Ansprechen in Präsenzzeit (Vorlesung/Übung)
 - E-Mail: f.heinrichs@fh-aachen.de

Überblick & Grundbegriffe

2. Organisatorisches

Fragen?

Diese Vorlesung wird weiterentwickelt. Wenn Sie Fehler auf den Folien finden, melden Sie sie gerne:

Beispiel:

E-Mail an: f.heinrichs@fh-aachen.de

Betreff: [DS AC] Folie 1-32

Inhalt: Beschreibung des Fehlers

Überblick & Grundbegriffe

Rückblick

- Was ist das (abstrakte) Ziel von Data Science?
- Im Schnitt welcher drei Gebiete befindet sich Data Science?
- Aus welchen Schritten besteht eine "typische" Data Science Pipeline?
- Was ist ein typischer Schritt...
 - ...der Datenbeschaffung/-aufbereitung?
 - ...der explorativen Datenanalyse?
 - ...des Feature Engineerings
 - ...der Modellierung?
- Wie unterscheiden sich Data Scientist und Data Engineer?
- Ist die explorative Datenanalyse ein linearer Prozess?
 - Und die Data Science Pipeline?
- Was ist der Unterschied zwischen klassischer Software und maschinellem Lernen?