

Einführung in Data Science

Eindimensionale EDA und Visualisierungen



Eindimensionale EDA und Visualisierungen

Inhalte

1. Überblick & Grundbegriffe
2. Einführung in Python (NumPy und Pandas)
- ➔ 3. Eindimensionale EDA und Visualisierungen
4. Visualisierungen und mehrdimensionale EDA
5. Mehrdimensionale EDA
6. Dimensionsreduktion: PCA
7. Dimensionsreduktion: MDS, Isomap
8. Clustering: Algorithmen
9. Clustering: Validierung
10. Probeklausur
11. Feature Engineering, datengetriebene Modelle
12. Datengetriebene Modelle
13. Zeitreihen

Überblick &
Grundlagen

Explorative
(Daten-)
Analyse (EDA)

Feature
Engineering &
Modellierung







Heute

1. Wiederholung
2. Explorative Datenanalyse (EDA)
3. Visualisierung

1. Wiederholung

1. Wiederholung

BCI




2. Explorative Datenanalyse (EDA)

2. Explorative Datenanalyse

- Basiert auf Arbeiten der Statistiker an den Bell Laboratories (1960er Jahre)
- Begriff stammt von John W. Tukey (amerikanischer Statistiker)
- „Was können die Daten uns erzählen?“ (daten-getriebenes Arbeiten ergänzt Hypothesen-getriebenes Arbeiten)
- Einführung verschiedener Techniken, wie 5-Number-Summary und Box-Plots



John W. Tukey
(1915 – 2000)



Pearson Modern Classic

Quelle: Amazon, Wikipedia

2. Explorative Datenanalyse

- Ziele der explorativen Datenanalyse
 1. Identifikation von Problemen im Datensatz
 2. Einschätzung zu Annahmen in Daten
 3. Auswahl von passenden statistischen Methoden
 4. Hypothesen über Daten bilden
- Typische Werkzeuge
 - Deskriptive Statistik
 - Visualisierung
 - Dokumentation des Erkenntniswegs !!!
 - ... zur Steuerung der eigenen Analysen
 - ... zur Kommunikation und Diskussion der Ergebnisse mit Dritten
 - ... zur Sicherung der Reproduzierbarkeit


2. Explorative Datenanalyse

Dokumentation

- Dokumentation unterscheidet sich je nach Arbeitsumfeld / Gruppe
- Beispiele
 - Jupyter Notebooks (typisch im Bereich Data Science)
 - PowerPoint (in der Industrie, Beratung)
 - Kommentierter Code

2. Explorative Datenanalyse

Deskriptive Statistik



2. Explorative Datenanalyse

Deskriptive Statistik

- Kennzahlen (englisch: Summary Statistics)
 - Beschreiben eine Stichprobe (Häufigkeitsverteilung) in wenigen Zahlen

Typ	Verwendung	Beispiele
Lagemaß	Beschreiben Lage einer Stichprobe: Wenn alle Beobachtungen um c verschoben werden, verschiebt sich auch das Lagemaß um c $f(x_1 + c, \dots, x_n + c) = f(x_1, \dots, x_n) + c$	• Mittelwert / Durchschnitt • Median • Modus (häufigster Wert) • Quantile
Streuemaß	Beschreiben Streuung einer Stichprobe: Verändert sich bei Verschiebung nicht $f(x_1 + c, \dots, x_n + c) = f(x_1, \dots, x_n)$	• Varianz • Standardabweichung • Interquartilsabstand

2. Explorative Datenanalyse

Deskriptive Statistik

➤ „5 Number Summary“ (5-Punkte-Zusammenfassung) nach Tukey

- Minimum
- Unteres Quartil
- Median
- Oberes Quartil
- Maximum

Beispiel

1, 25, 26, 28, 29, 29, 39, 42, 45, 51, 56, 61, 81, 85, 89

1 28 42 61 89

2. Explorative Datenanalyse

Deskriptive Statistik

- Was ist ein Quartil?
- Allgemeiner: Was ist ein p -Quantil?

Empirisches p -Quantil

Sei $x_1, \dots, x_n$ eine Stichprobe der Größe n .

- Die *Ordnungsstatistik* entspricht der Sortierung der Stichprobe: $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$
- Für $p \in (0, 1)$ heißt

$$q_p = \begin{cases} \frac{1}{2}(x_{(n \cdot p)} + x_{(n \cdot p + 1)}), & \text{falls } n \cdot p \in \mathbb{N} \\ x_{(\lfloor n \cdot p + 1 \rfloor)}, & \text{falls } n \cdot p \notin \mathbb{N} \end{cases}$$

das (*empirische*) p -Quantil der Stichprobe.

Notation: Sei $\lfloor x \rfloor$ die Abrundungsfunktion, z.B. $\lfloor 5.6 \rfloor = 5$.

2. Explorative Datenanalyse

Deskriptive Statistik

- Median: $q_{0.5}$ (50%-Quantil)
- Unteres Quartil: $q_{0.25}$ (25%-Quantil)
- Oberes Quartil: $q_{0.75}$ (75%-Quantil)
- Eigenschaft:
 - $n \cdot p$ Beobachtungen sind $\leq q_p$
 - $n(1 - p)$ Beobachtungen sind $\geq q_p$

Beispiel


- Stichprobe:
68, 95, 2, 33, 86, 58, 64
- Ordnungsstatistik:
2, 33, 58, 64, 68, 86, 95
- Median: $0.5 \cdot 7 = 3.5 \notin \mathbb{N}$
 $\Rightarrow q_{0.5} = x_{(\lfloor 3.5+1 \rfloor)} = x_{(4)} = 64$
- Unteres Quartil: $0.25 \cdot 7 = 1.75 \notin \mathbb{N}$
 $\Rightarrow q_{0.25} = x_{(\lfloor 1.75+1 \rfloor)} = x_{(2)} = 33$
- Oberes Quartil: $0.75 \cdot 7 = 5.25 \notin \mathbb{N}$
 $\Rightarrow q_{0.75} = x_{(\lfloor 5.25+1 \rfloor)} = x_{(6)} = 86$

2. Explorative Datenanalyse

Deskriptive Statistik

Boxplot (nach J.W. Tukey)

Punkte mit einem Abstand zum nächsten Quartil größer als $1.5 \cdot IQR$ werden *Ausreißer* genannt.




Bildquelle: Wikipedia

2. Explorative Datenanalyse

Deskriptive Statistik

Boxplot (Alternative Variante, eher selten)



Unterschied zur Tukey-Variante: Whisker werden durch extremste Werte begrenzt

Bildquelle: Wikipedia

2. Explorative Datenanalyse

Code in
topic03_eda/exercise1.py

Übung

1. Laden Sie den Datensatz `data/example.csv` mit Pandas.
2. Berechnen Sie anschließend mit NumPy das untere und obere Quartil, den Median, das Minimum und das Maximum.
3. Erstellen Sie einen zugehörigen Box-Plot mit Matplotlib.

2. Explorative Datenanalyse

Deskriptive Statistik

➤ 5 Number Summary – Beispiel¹

	Min	25%	Median	75%	Max
Age	241	418	584	748	959
Weight	32.4	67.2	78.8	92.6	218.2
Height	140	160	167	175	204
Leg Length	23.7	35.7	38.4	41	55.5
Arm Length	29.5	35.5	37.4	39.4	47.7
Arm Circumference	19.5	29.7	32.8	36.1	141.1
Waist	59.1	87.5	97.95	108.3	172

➤ Welche Auffälligkeiten sehen Sie in den Daten?

1: Daten des *National Health and Nutrition Examination Survey (NHANES)*, USA.

Langzeitstudie seit 1971 zu Gesundheitsstatus und Ernährungsgewohnheiten von Menschen in den USA.

2. Explorative Datenanalyse

Deskriptive Statistik

Weitere typische Kennzahlen (*summary statistics*)

➤ Lagemaß

Arithmetisches Mittel: $\bar{x}_n = \frac{1}{n} \sum_{i=1}^n x_i$

➤ Streumaße

(empirische) Varianz: $\sigma^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x}_n)^2$

(empirische) Standardabweichung $\sigma = \sqrt{\sigma^2}$

2. Explorative Datenanalyse

Code in
topic03_eda/exercise2.py

Übung


1. Laden Sie den Datensatz `data/example.csv` mit Pandas.
2. Berechnen Sie anschließend mit NumPy den Mittelwert, die empirische Standardabweichung und die empirische Varianz.

2. Explorative Datenanalyse


Deskriptive Statistik

Wie schätzen Sie die Aussagekraft von Mittelwert und Varianz bei folgenden Verteilungen ein?

Unimodale Verteilung



Multimodale Verteilung






2. Explorative Datenanalyse

Code in `topic03_eda/histograms.py`

Deskriptive Statistik




- Histogramm: Graphische Darstellung der Verteilung einer Stichprobe durch Einteilen der Daten in Klassen (engl. *Bins*)

100 Datenpunkte
einer (Standard-)
Normalverteilung



Anzahl der Bins
angemessen
wählen!

10000 Datenpunkte
einer (Standard-)
Normalverteilung



2. Explorative Datenanalyse

Deskriptive Statistik

- Reichen Kennzahlen, um einen Datensatz zu beschreiben?
- „Anscombes Quartett“

- Kennzahlen sind gleich
- Datensätze sind unterschiedlich
 - Aber: Wie unterschiedlich?
 - Visualisierung!


Kennzahlen

	I		II		III		IV	
	x	y	x	y	x	y	x	y
	10.0	8.04	10.0	9.14	10.0	7.46	8.0	6.58
	8.0	6.95	8.0	8.14	8.0	6.77	8.0	5.76
	13.0	7.58	13.0	8.74	13.0	12.74	8.0	7.71
	9.0	8.81	9.0	8.77	9.0	7.11	8.0	8.84
	11.0	8.33	11.0	9.26	11.0	7.81	8.0	8.47
	14.0	9.96	14.0	8.10	14.0	8.84	8.0	7.04
	6.0	7.24	6.0	6.13	6.0	6.08	8.0	5.25
	4.0	4.26	4.0	3.10	4.0	5.39	19.0	12.50
	12.0	10.84	12.0	9.31	12.0	8.15	8.0	5.56
	7.0	4.82	7.0	7.26	7.0	6.42	8.0	7.91
	5.0	5.68	5.0	4.74	5.0	5.73	8.0	6.89
Mean	9.0	7.5	9.0	7.5	9.0	7.5	9.0	7.5
Var.	10.0	3.75	10.0	3.75	10.0	3.75	10.0	3.75
Corr.	0.816		0.816		0.816		0.816	

2. Explorative Datenanalyse

Code in [topic03_eda/anscombe.py](#)

Visualisierung des Anscombes Quartett¹



1: Daten wurden 1971 vom englischen Statistiker Francis Anscombe erzeugt, um die Wichtigkeit von Datenvisualisierung zu demonstrieren.


3. Visualisierung

3. Visualisierung

- Ziele der explorativen Datenanalyse
 1. Identifikation von Problemen im Datensatz
 2. Einschätzung zu Annahmen in Daten
 3. Auswahl von passenden statistischen Methoden
 4. Hypothesen über Daten bilden
- Typische Werkzeuge
 - Deskriptive Statistik
 - Dokumentation des Erkenntniswegs
 - Visualisierung
 - ... erlaubt schnelle, visuelle Exploration von Mustern
 - ... hilfreiches Instrument zur Kommunikation von Ergebnissen

3. Visualisierung


➤ Beispiel I



- Skalierung von x - und y -Achsen können Preisentwicklung dramatisieren oder entdramatisieren

3. Visualisierung


➤ Beispiel II



- Manipulative x -Achsen Skalierung suggeriert auf den ersten Blick geringe Frauenanteile; schwierig, Fakultätsgrößen in absoluten Zahlen abzulesen

3. Visualisierung


➤ Beispiel II (besser)



➤ Falls Aufteilung nach Geschlecht: **Keine** logarithmische Transformation!

3. Visualisierung


- **Beispiel III**
- Dritte Dimension überflüssig und verwirrend
- Zusätzlicher Balken rechts ohne Jahresdatum



3. Visualisierung

Code in `topic03_eda/bar_chart.py`


➤ Beispiel III (besser)



3. Visualisierung


➤ Beispiel IV

Who is Buying in San Francisco?




3. Visualisierung

➤ Beispiel IV (besser)



3. Visualisierung

➤ Beispiel V




3. Visualisierung

➤ **Beispiel V** (besser)

Fruit Collected				
Banana				
Apple				
Cherry				



3. Visualisierung

➤ Beispiel VI




3. Visualisierung

➤ Beispiel VII




3. Visualisierung

➤ Beispiel VIII




3. Visualisierung

- **Beispiel IX**
- Wie viele Werte werden angezeigt?
 - 5
- 6 Farben
- Geteilte y-Achse mit redundanten Informationen
- Unnötige dreidimensionale Darstellung




3. Visualisierung

➤ Beispiel IX (besser)



3. Visualisierung

➤ Beispiel X



3. Visualisierung

➤ **Regeln nach Edward Tufte**

(US-amerikanischer Informationswissenschaftler; bis 2004 Yale University)

1. Maximieren Sie das Daten-Druckerschwärze Verhältnis
(auf Deutsch: so wenig Druckerschwärze für so viele Daten wie möglich)
2. Minimieren Sie den Lügenfaktor
3. Minimieren Sie „Chartjunk“
(keine visuellen Spielereien; lassen Sie die Daten für sich selber sprechen)
4. Nutzen Sie angemessene Skalen; beschriften Sie Ihre Achsen

3. Visualisierung

Code in
topic03_eda/exercise3.py

Übung

1. Laden Sie den Datensatz `data/example.csv` mit Pandas.
2. Visualisieren Sie den Datensatz mit einem line plot (Liniendiagramm).
3. Visualisieren Sie den Datensatz anschließend mit einem scatter plot (Streudiagramm). Unterteilen Sie die Abbildung dafür in 2 subplots mit `plt.subplot()`.

3. Visualisierung

Ressourcen

- Matplotlib Dokumentation: <https://matplotlib.org/>
- Seaborn Dokumentation: <https://seaborn.pydata.org/>
- Kaggle Tutorial: <https://www.kaggle.com/learn/data-visualization>

Explorative Datenanalyse

Rückblick

- Was sind die Ziele der explorativen Datenanalyse?
- Was sind "typische Werkzeuge" der EDA?
- Wie unterscheiden sich deskriptive und Inferenzstatistik?
- Was sind Beispiele für typische Lagemaße? Und Streumaße?
- Wie bestimmen wir Quantile?
- Was sind Median, unteres und oberes Quartil?
- Wie ist ein Boxplot aufgebaut?
- Was sind typische "Fehler" beim Visualisieren von Daten?
- Was sind Best Practices der Visualisierung von Daten?