

Einführung in Data Science

Visualisierungen und Mehrdimensionale EDA

Eindimensionale EDA und Visualisierungen

Inhalte

1. Überblick & Grundbegriffe
2. Einführung in Python (NumPy und Pandas)
3. Eindimensionale EDA und Visualisierungen
- ➔ 4. Visualisierungen und mehrdimensionale EDA
5. Mehrdimensionale EDA
6. Dimensionsreduktion: PCA
7. Dimensionsreduktion: MDS, Isomap
8. Clustering: Algorithmen
9. Clustering: Validierung
10. Probeklausur
11. Feature Engineering, datengetriebene Modelle
12. Datengetriebene Modelle
13. Zeitreihen

Überblick &
Grundlagen

Explorative
(Daten-)
Analyse (EDA)

Feature
Engineering &
Modellierung

Heute

1. Wiederholung
2. Visualisierung
3. Multivariate Explorative Datenanalyse (EDA)

1. Wiederholung

1. Wiederholung

- Ziele der explorativen Datenanalyse
 1. Identifikation von Problemen im Datensatz
 2. Einschätzung zu Annahmen in Daten
 3. Auswahl von passenden statistischen Methoden
 4. Hypothesen über Daten bilden
- Typische Werkzeuge
 - Deskriptive Statistik
 - Visualisierung
 - Dokumentation des Erkenntniswegs


1. Wiederholung

Dokumentation

- Dokumentation unterscheidet sich je nach Arbeitsumfeld / Gruppe
- Beispiele
 - Jupyter Notebooks (typisch im Bereich Data Science)
 - PowerPoint (in der Industrie, Beratung)
 - Kommentierter Code

1. Wiederholung

Deskriptive Statistik



1. Wiederholung

Deskriptive Statistik

➤ „5 Number Summary“ (5-Punkte-Zusammenfassung)


- Minimum
- Unteres Quartil
- Median
- Oberes Quartil
- Maximum

Beispiel

1, 25, 26, 28, 29, 29, 39, 42, 45, 51, 56, 61, 81, 85, 89

1 28 42 61 89


➤ Boxplot



1. Wiederholung

Deskriptive Statistik



- Summary Statistics (Kennzahlen) hilfreich als Zusammenfassung der Daten
- Aber: Unterschiedliche Daten können ähnliche Kennzahlen haben
 - Wir benötigen Visualisierungen zur Erkundung der Daten!
- Beispiel: „Data Saurus“ – aus dem Paper „Same Stats, Different Graphs“¹



1: Matejka, J., & Fitzmaurice, G. (2017, May). Same stats, different graphs: generating datasets with varied appearance and identical statistics through simulated annealing. In *Proceedings of the 2017 CHI conference on human factors in computing systems* (pp. 1290-1294).



1. Wiederholung

➤ **Beispiel** für problematische Abbildungen



1. Wiederholung

➤ Beispiel für problematische Abbildungen



2. Visualisierung (Fortsetzung)

2. Visualisierung

Edward Tufte

- US-amerikanischer Statistiker
- Bis 2004 Professur an der Yale University
- Pionier im Bereich Datenvisualisierung
- Literatur zur Datenvisualisierung:
 - „Beautiful Evidence“ (2006)
 - „PowerPoint is Evil“ (2003)
 - „Envisioning Information“ (2001)
 - „Visual Explanations“ (1997)



Quelle: Wikipedia



2. Visualisierung

Prinzipien guter Visualisierung (nach Tufte)

1. Maximieren Sie das Daten-Druckerschwärze Verhältnis (*data-ink-ratio*)

$$q = \frac{\text{Tintenmenge für die Darstellung von Daten}}{\text{Tinten der gesamten Abbildung}}$$

Auf Deutsch: Nur so viel Tinte wie nötig (so wenig wie möglich)




2. Visualisierung

Prinzipien guter Visualisierung (nach Tufte)

2. Minimieren Sie den Lügenfaktor

$$\ell = \frac{\text{Größe eines Effekts in der Abbildung}}{\text{Größe eines Effekts in den Daten}}$$

Auf Deutsch: Leiten Sie Ihr Publikum nicht fehl



Wo ist das Problem? → Logarithmische Darstellung suggeriert kleineren Frauenanteil

2. Visualisierung

Prinzipien guter Visualisierung (nach Tufte)

2. Minimieren Sie den Lügenfaktor

$$\ell = \frac{\text{Größe eines Effekts in der Abbildung}}{\text{Größe eines Effekts in den Daten}}$$

Bad Practices*:

- Mittelwert ohne Standardabweichung angeben
- Interpolierte Werte ohne tatsächliche Daten zeigen
- Seitenverhältnis manipulieren, um Daten zu dramatisieren
- Koordinatenursprung nicht zeigen (Standard in matplotlib!)
- Achsen nicht oder irreführend beschriften

Weitere Bad Practices?

*natürlich gibt es Ausnahmen

2. Visualisierung

Prinzipien guter Visualisierung (nach Tufte)

3. Minimieren Sie „Chartjunk“

- *Chartjunk*: Visuelle Elemente in Abbildungen, die unnötig sind oder das Verständnis erschweren

4. Nutzen Sie angemessene Skalen und Beschriftungen

- z.B. Beschriftung der Achsen

5. **Farbe** zum Darstellen von Eigenschaften der Daten – nicht für künstlerische Aussage!

*Weitere Hinweise zu Visualisierung finden Sie unter anderem im Paper „Ten Simple Rules for Better Figures“ von N.P. Rougier et al, PLOS Comput. Biol. 10, e1003833, 2014

2. Visualisierung

Übung

Arbeiten Sie zu zweit.


1. Betrachten Sie den folgenden Farbverlauf namens „Jet“

niedrig  hoch



Die rechts stehende Abbildung wurde mit dem Farbverlauf erzeugt und dann in Graustufen dargestellt.

2. Identifizieren Sie: Wo sind die Minima, wo die Maxima in der rechten Abbildung?

3. Sammeln Sie: Was finden Sie problematisch?



2. Visualisierung



Farbverlauf „Jet“



Leuchtdichte (*engl: luminance*)







Erkenntnis 1: Farbverlauf „Jet“ hat ein kompliziertes Leuchtdichteprofil.
→ schwierig zu interpretieren bei Graustufenabbildung

2. Visualisierung

Zu zweit: Beschreiben Sie die Daten, was fällt Ihnen auf?


$$f(x, y) = \frac{\cos(11.5\pi x) y^2}{10}$$

Erkenntnis 2: Farbverlauf „Jet“ betont vermeintliche „Eigenschaften“ der Eigenschaften, die gar nicht existieren



2. Visualisierung

Warum sehen wir mit Farbverlauf *Jet* (und einigen anderen) vermeintliche Muster in den Daten? → Menschliche Wahrnehmung



Was wir eigentlich wollen:

Gleiche Unterschiede zwischen Datenpunkten sollen sich in gleichen perzeptuellen (wahrnehmbaren) Unterschieden in den Farben widerspiegeln


Modell f der menschlichen Farbwahrnehmung

2. Visualisierung

Was wir wollen

- Gleiche Unterschiede in Daten → gleiche Unterschiede in Farben
- Genauer: Gleiche wahrgenommene Farbunterschiede
- Beispiel
 - Daten: $x = [0.1, 0.2, 0.8, 0.9]$
 - Unterschiede: $\Delta x^{(1)} = x_2 - x_1 = 0.1$ und $\Delta x^{(2)} = x_4 - x_3 = 0.1$

Beobachtung
 $\frac{df}{dx} \neq \text{const}$



Quelle: <https://bids.github.io/colormap/>


2. Visualisierung

Was wir wollen

- Gleiche Unterschiede in Daten → gleiche Unterschiede in Farben
- Genauer: Gleiche wahrgenommene Farbunterschiede
- Beispiel
 - Daten: $x = [0.1, 0.2, 0.8, 0.9]$
 - Unterschiede: $\Delta x^{(1)} = x_2 - x_1 = 0.1$ und $\Delta x^{(2)} = x_4 - x_3 = 0.1$

Standard in
matplotlib!

Beobachtung
 $\frac{df}{dx} = \text{const}$



Quelle: <https://bids.github.io/colormap/>

2. Visualisierung

Viridis und andere Farbverläufe

- Optimiert bzgl. Farbwahrnehmung
- Nutzbar auch bei Graustufen
- Optimiert bzgl. Verschiedener Farbfehlsichtigkeiten (z.B. Rot/Grün Sehschwäche)

Wie viel Prozent aller Menschen haben eine Fehlsichtigkeit?

- Männer: 8%, Frauen: 0.5%¹

Wie viel Prozent aller Menschen haben eine Rot/Grün Fehlsichtigkeit?

- Männer: 5%, Frauen: 0.4%¹

Magma

Inferno


Plasma

Viridis

1: Kalloniatis M, Luu C (2007). "The Perception of Color". In Kolb H et al (eds.). The Organization of the Retina and Visual System

Quelle: <https://bids.github.io/colormap/>

2. Visualisierung



Quelle: Andrew Abela. *Advanced Presentation by Design*. Pfeiffer, 2. Auflage, 2013; <https://bit.ly/2QIXNyQ>

2. Visualisierung

matplotlib

Plot types User guide Tutorials Examples Reference Contribute Releases

3.10 (stable)

Section Navigation

- Lines, bars and markers
- Images, contours and fields
- Subplots, axes and figures
- Statistics
- Pie and polar charts
- Text, labels and annotations
- Color
- Shapes and collections
- Style sheets
- Module - pyplot
- Module - axes_grid1
- Module - axisartist
- Showcase
- Animation
- Event handling
- Miscellaneous
- 3D plotting
- Scales
- Specialty plots
- Spines
- Ticks
- Units
- Embedding Matplotlib in graphical user interfaces

outline: bar and markers/index.html

Examples

Examples

For an overview of the plotting methods we provide, see [Plot types](#)


This page contains example plots. Click on any image to see the full image and source code.

For longer tutorials, see our [tutorials page](#). You can also find [external resources](#) and a [FAQ](#) in our [user guide](#).

Tagging!


You can also browse the example gallery by [tags](#).

Lines, bars and markers



On this page

- Lines, bars and markers
- Images, contours and fields
- Subplots, axes and figures
- Statistics
- Pie and polar charts
- Text, labels and annotations
- Color
- Shapes and collections
- Style sheets
- Module - pyplot
- Module - axes_grid1
- Module - axisartist
- Showcase
- Animation
- Event handling
- Miscellaneous
- 3D plotting
- Scales
- Specialty plots
- Spines
- Ticks
- Units
- Embedding Matplotlib in graphical user interfaces
- Widgets
- Userdemo



Quelle: <https://matplotlib.org/stable/gallery/index.html>

3. Multivariate EDA

3. Multivariate EDA

➤ Bisher:

- Univariate (eindimensionale) Daten: ein Merkmal bzw. Feature
- Methoden der univariaten deskriptiven Statistik und EDA (Kennzahlen für Lage und Streuung, Boxplots, ...)

➤ Jetzt:

- Multivariate (mehrdimensionale) Daten: mehr als ein Merkmal bzw. Feature
- Methoden der multivariaten deskriptiven Statistik und EDA

➤ Beispiel:

- Mietpreise für Wohnungen (univariat)
- Abhängigkeit zwischen Mietpreisen und Wohnungsgröße (multivariat)

Quelle: <https://bids.github.io/colormap/>


3. Multivariate EDA

Scatterplot (Streudiagramm)

- Darstellung der Wertepaare (x_i, y_i) zweier Features (Merkmale) X, Y
 - Bivariate Darstellung
- Erleichtert Identifikation von Abhängigkeitsstrukturen zwischen Merkmalen
- Natürlich Darstellung zweidimensionaler Daten
- Python

```
import matplotlib.pyplot as plt  
plt.scatter(x, y)
```

Daten: Münchener Mietspiegel (2015)



Wie könnten Sie ein drittes Merkmal visualisieren, z.B. die Anzahl der Zimmer?


3. Multivariate EDA

Bubble Chart (Blasendiagramm)

- Darstellung der Wertetupel (x_i, y_i, z_i) dreier Features (Merkmale) X, Y, Z
 - Trivariate Darstellung
- Python

```
import matplotlib.pyplot as plt  
plt.scatter(x, y, s=z)
```

Wie könnten Sie ein viertes Merkmal visualisieren, z.B. den Kontinent?



3. Multivariate EDA

Code in `topic04_visualization/
exercise_multivariate_plot.py`

Übung


1. Laden Sie den Datensatz `data/example2.csv` mit Pandas.
2. Visualisieren Sie zunächst die Spalten X und Y mit einem Scatterplot.
3. Visualisieren Sie anschließend zusätzlich Spalte Z mit einem Bubble Chart.
4. Visualisieren Sie schließlich alle 4 Spalten mit einem geeigneten Plot.
 - Was fällt Ihnen auf?

3. Multivariate EDA

Charakterisierung von Zusammenhängen durch Abhängigkeitsmaße

- Maße zur Quantifizierung der **Stärke** eines Zusammenhangs
- Maße zur Charakterisierung der **Richtung** eines Zusammenhangs
- Maße zur Charakterisierung der **Direkt-/Indirektheit** eines Zusammenhangs (meist n -variante Maße, für $n \geq 3$)

Daten: Münchener Mietspiegel (2015)



3. Multivariate EDA

Bivariate Maße zur Quantifizierung der **Stärke** eines Zusammenhangs

- (Pearsons) Korrelationskoeffizient
- Spearmans Korrelationskoeffizient
- Kendall's Tau
- Goodman und Kruskals Gamma
- Yule's Q
- Chatterjee's Korrelation
- ...

Warum gibt es so viele unterschiedliche Maße?

3. Multivariate EDA

(Pearsons/empirischer) **Korrelationskoeffizient**

- Seien X und Y Merkmale (Features)
- Sei $(x_1, y_1), \dots, (x_n, y_n)$ eine Stichprobe gepaarter Daten der Größe n
- Definiere die empirischen Mittelwerte $\bar{x}_n = \frac{1}{n} \sum_{i=1}^n x_i$ und $\bar{y}_n = \frac{1}{n} \sum_{i=1}^n y_i$
- Der (Pearson) Korrelationskoeffizient r ist definiert als

$$r = r_{XY} = \frac{\sum_{i=1}^n (x_i - \bar{x}_n)(y_i - \bar{y}_n)}{\sqrt{\sum_{i=1}^n (x_i - \bar{x}_n)^2 \sum_{i=1}^n (y_i - \bar{y}_n)^2}} = \frac{s_{XY}}{s_X s_Y}$$

mit

$$s_X^2 = \sum_{i=1}^n (x_i - \bar{x}_n)^2, \quad s_Y^2 = \sum_{i=1}^n (y_i - \bar{y}_n)^2, \quad s_{XY} = \sum_{i=1}^n (x_i - \bar{x}_n)(y_i - \bar{y}_n)$$


(empirische) Varianz (emp.) Kovarianz

3. Multivariate EDA

Kovarianz

$$s_{XY} = \sum_{i=1}^n \underbrace{(x_i - \bar{x}_n)(y_i - \bar{y}_n)}$$

Vorzeichen jedes Summanden ergibt sich aus Lage von (x_i, y_i) gegenüber $(\bar{x}_n, \bar{y}_n)$



3. Multivariate EDA

(Pearsons/empirischer) **Korrelationskoeffizient**

- r ist normiert, d.h. $-1 \leq r \leq 1$
- r misst die Stärke des linearen Zusammenhangs
 - Je näher die Messwerte an einer Geraden liegen, desto näher liegt r
bei $\begin{cases} 1, \text{ falls die Gerade positive Steigung hat} \\ -1, \text{ falls die Gerade negative Steigung hat} \\ 0, \text{ falls die Gerade konstant ist} \end{cases}$
- Wann liegt eine Korrelation vor?
 - Kontextabhängig!
 - Rule-of-thumb:
 - Schwache Korrelation: $|r| < 0.5$
 - Mittlere Korrelation: $0.5 \leq |r| < 0.8$
 - Starke Korrelation: $|r| \geq 0.8$

3. Multivariate EDA

(Pearsons/empirischer) **Korrelationskoeffizient**

Wie groß ist die Korrelation jeweils für die abgebildeten Datensätze?

1. Alleine: Schätzen Sie die Korrelation.
2. Zu zweit: Besprechen Sie Ihre geschätzten Werte.



Visualisierung und multivariate EDA

Rückblick

- Was beschreibt das Daten-Druckschwärze Verhältnis?
- Warum sollte das Verhältnis

$$\ell = \frac{\text{Größe eines Effekts in der Abbildung}}{\text{Größe eines Effekts in den Daten}}$$

möglichst nah bei 1 sein?

- Was sind Bad Practices für Visualisierungen?
- Was ist Chartjunk?
- Warum sind manche Farbverläufe besser für Visualisierungen geeignet als andere?
- Was ist der Unterschied zwischen univariater und multivariater EDA?
- Wie können wir 2- bzw. 3-dimensionale Daten visualisieren?
- Was beschreibt der (Pearson) Korrelationskoeffizient?