

Einführung in Data Science

Mehrdimensionale EDA



Eindimensionale EDA und Visualisierungen

Inhalte

1. Überblick & Grundbegriffe
2. Einführung in Python (NumPy und Pandas)
3. Eindimensionale EDA und Visualisierungen
4. Visualisierungen und mehrdimensionale EDA
- ➡ 5. Mehrdimensionale EDA
6. Dimensionsreduktion: PCA
7. Dimensionsreduktion: MDS, Isomap
8. Clustering: Algorithmen
9. Clustering: Validierung
10. Probeklausur
11. Feature Engineering, datengetriebene Modelle
12. Datengetriebene Modelle
13. Zeitreihen

Überblick &
Grundlagen

Explorative
(Daten-)
Analyse (EDA)

Feature
Engineering &
Modellierung

Heute


1. Wiederholung
2. Multivariate Explorative Datenanalyse (EDA)

1. Wiederholung

1. Wiederholung

Scatterplot (Streudiagramm)


Daten: Münchener Mietspiegel (2015)



```
import matplotlib.pyplot as plt
plt.scatter(x, y)
```

Bubble Chart (Blasendiagramm)

Kreisflächen: proportional zur
Bevölkerungsanzahl im jeweiligen Land



```
import matplotlib.pyplot as plt
plt.scatter(x, y, s=z)
```

1. Wiederholung

(Pearsons/empirischer) **Korrelationskoeffizient**

- Empirischen Mittelwerte

$$\bar{x}_n = \frac{1}{n} \sum_{i=1}^n x_i \text{ und } \bar{y}_n = \frac{1}{n} \sum_{i=1}^n y_i$$

- Empirische Standardabweichung

$$s_X^2 = \sum_{i=1}^n (x_i - \bar{x}_n)^2 \text{ und } s_Y^2 = \sum_{i=1}^n (y_i - \bar{y}_n)^2$$

- Empirische Kovarianz

$$s_{XY} = \sum_{i=1}^n (x_i - \bar{x}_n)(y_i - \bar{y}_n)$$

- Pearson Korrelationskoeffizient

$$r = \frac{s_{XY}}{s_X s_Y}$$

1. Wiederholung

(Pearsons/empirischer) **Korrelationskoeffizient**

Wie groß ist die Korrelation jeweils für die abgebildeten Datensätze?




2. Multivariate EDA


2. Multivariate EDA

Wie können wir d -dimensionale Daten visualisieren?


$d = 1$



$d = 2$




$d = 3$



$d = 4?$ $d \in \mathbb{N}?$



2. Multivariate EDA

Wie können wir d -dimensionale Daten visualisieren?



2. Multivariate EDA



Jedes Element $x \in \mathbb{R}^d$ entspricht einer Kurve (d Punkte)



2. Multivariate EDA

Grundsätzlich gibt es keinen Zusammenhang zwischen Koordinaten eines Vektors




➤ Manchmal gibt es aber Zusammenhänge!



2. Multivariate EDA

Beispiel

- Nahinfrarotspektren von Fleischsorten
- Farbliche Kodierung: Fettgehalt (hoch/niedrig)
- Messung des Spektrums bei 100 Wellenlängen
 - Jede Messung: $x = (x_1, \dots, x_{100})$
 - Ist das sinnvoll?
- Informationen über Zusammenhang gehen verloren
- Stattdessen: $x = x(t)$ (Funktion!)



→ Funktionale
Datenanalyse (FDA)


2. Multivariate EDA

Parallel Coordinate Plot (PCP)

- Technik zur Visualisierung multivariater Daten
- Hilfreich bei Exploration höherdimensionaler Räume
- Koordinaten werden auf parallelen Achsen dargestellt

Beispiel (Iris-Datensatz)

- Schwertlilien: 150 Pflanzen mit 4 Merkmalen (Features)
- 3 Iris-Arten: Setosa, Versicolor, Virginica
- Merkmale: Jeweils Länge und Breite der von Kron- und Kelchblatt (*Petal* bzw. *Sepal*)



Quelle: Wikipedia

2. Multivariate EDA

Parallel Coordinate Plot (PCP)


- Mehrdimensionale Strukturen werden in PCPs sichtbar

Beispiel ($n = 2$):

- Streudiagramme



- Parallel Coordinate Plots



Quelle: Wikipedia

2. Multivariate EDA


Parallel Coordinate Plot (PCP)

Welche Strukturen erkennen Sie im dargestellten PCP?

- Achsen 3, 4, 5: Zwei 3-dimensionale Cluster
- Achsen 3, 4, 5: Datenpunkt des unteren Clusters parallel
- Achsen 2, 3: Merkmale negativ korreliert

Welche Faktoren beeinflussen die Visualisierung des PCPs?

- Achsenpermutation (Korrelation nur bei benachbarten Achsen gut erkennbar)
- Achsenskalierung



2. Multivariate EDA

Code in `topic05_multivariate_eda/exercise_pcp.py`

Parallel Coordinate Plot (PCP)

Übung

Erstellen Sie einen Parallel Coordinate Plot mit Python, indem Sie...

- ... den Iris Datensatz mit scikit-learn laden


```
from sklearn.datasets import load_iris
```

- ... die Pandas Methode `parallel_coordinates` nutzen

```
from pandas.plotting import parallel_coordinates
```

Dokumentation:

https://pandas.pydata.org/docs/reference/api/pandas.plotting.parallel_coordinates.html




Quelle: Wikipedia

2. Multivariate EDA

Charakterisierung von Zusammenhängen durch Abhängigkeitsmaße

- Maße zur Quantifizierung der **Stärke** eines Zusammenhangs
- Maße zur Charakterisierung der **Richtung** eines Zusammenhangs
- Maße zur Charakterisierung der **Direkt-/Indirektheit** eines Zusammenhangs (meist n -variante Maße, für $n \geq 3$)

Daten: Münchener Mietspiegel (2015)



3. Multivariate EDA

Bivariate Maße zur Quantifizierung der **Stärke** eines Zusammenhangs

- (Pearsons) Korrelationskoeffizient
- ➡ ➤ Spearman's Korrelationskoeffizient
- Kendall's Tau
- Goodman und Kruskals Gamma
- Yule's Q
- Chatterjee's Korrelation
- ...

2. Multivariate EDA

Spearman Korrelationskoeffizient

- ... entspricht dem Pearson Korrelationskoeffizienten für die Ränge der Werte
- Sei $x_1, \dots, x_n$ eine Stichprobe und $x_{(1)}, \dots, x_{(n)}$ die Ordnungsstatistik mit $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$
- Dann ist der Rang eines Wertes definiert als der zugehörige Index der Ordnungsstatistik

$$\text{rang}(x_i) = rg(x_i) = k, \quad \text{mit } x_i = x_{(k)}$$

- Tritt derselbe Wert mehrfach auf, spricht man von *Tie* bzw. *Bindung*. Der Rang aller identischen Werte wird mit dem Mittelwert der Ränge dieser Werte ersetzt.
- Der Spearman Korrelationskoeffizient ρ_s ist definiert als

$$\rho_s = \frac{\sum_{i=1}^n (rg(x_i) - \frac{n+1}{2})(rg(y_i) - \frac{n+1}{2})}{\sqrt{\sum_{i=1}^n (rg(x_i) - \frac{n+1}{2})^2 \sum_{i=1}^n (rg(y_i) - \frac{n+1}{2})^2}}$$

Warum?

2. Multivariate EDA

Spearman Korrelationskoeffizient

Umgang mit identischen Werten („Tie“, „Bindung“)

- Rangvergabe nicht eindeutig
- Stattdessen: Bilde Durchschnittsrang


Beispiel

x_i	1.09	2.17	2.17	2.17	3.02	4.5
	1	3	2	4	5	6
		$(2 + 3 + 4)/3 = 3$				
$rg(x_i)$	1	3	3	3	5	6

2. Multivariate EDA

Spearman Korrelationskoeffizient

- Der Pearson Korrelationskoeffizienten misst lineare Zusammenhänge
- Der Spearman Korrelationskoeffizient misst monotone Zusammenhänge
 - Warum? Was bedeutet das?




Zusammenhang ist monoton, aber nicht linear: $r_{XY} > 0$, aber $r_{XY} < 1$

Zusammenhang (der Ränge) ist linear, d.h. $\rho_s = 1$

2. Multivariate EDA

Spearman Korrelationskoeffizient

- Der Pearson Korrelationskoeffizienten misst lineare Zusammenhänge
- Der Spearman Korrelationskoeffizient misst monotone Zusammenhänge
 - Warum? Was bedeutet das?



Zusammenhang ist monoton, aber nicht linear: $r_{XY} < 0$, aber $r_{XY} > -1$

Zusammenhang (der Ränge) ist linear, d.h. $\rho_s = -1$

2. Multivariate EDA

Pearson vs. Spearman

Pearson	Spearman
Lineare Zusammenhänge	Monotone Zusammenhänge
Nutzbar für diskrete und stetige Merkmale (Features)	Nutzbar für ordinale , diskrete und stetige Merkmale
Beispiel: ➤ Nettomiete ➤ Alter	Beispiel: ➤ Schwierigkeitsgrade von Skipisten (blau, rot, schwarz) ➤ Noten (sehr gut, gut, befriedigend, ausreichend, mangelhaft)


2. Multivariate EDA

Code in `topic05_multivariate_eda/`
`exercise_correlation.py`

Pearson vs. Spearman (Übung)

- Visualisieren Sie die folgenden Zusammenhänge (vgl. Abbildung)
 - $f(x) = \log(10x + 0.01)$
 - $f(x) = \exp(10x)$
 - $f(x) = \sin(2\pi x)$
 - $f(x) = \sin(3\pi x)$
- Welche Werte für Pearson und Spearman Korrelation erwarten Sie jeweils? (Notieren Sie Ihre Vermutung)
- Bestimmen Sie anschließend die Korrelationskoeffizienten

```
from scipy.stats import spearmanr, pearsonr
```



2. Multivariate EDA

Pearson und Spearman

Invarianz unter linearer Transformation

- Betrachte linear transformierte Merkmale

$$\tilde{X} = a_X X + b_X$$

$$\tilde{Y} = a_Y Y + b_Y$$

- Es gilt

Übung!

$$r_{\tilde{X} \tilde{Y}} = \frac{a_X a_Y}{|a_X| \cdot |a_Y|} r_{XY} = \begin{cases} r_{XY}, & \text{falls } \text{sign}(a_X) = \text{sign}(a_Y) \\ -r_{XY}, & \text{falls } \text{sign}(a_X) \neq \text{sign}(a_Y) \end{cases}$$

- Insbesondere:

$$r_{\tilde{X} \tilde{Y}} = |r_{XY}|$$

2. Multivariate EDA

Spearman (nur Spearman!)

Invarianz unter streng monotonen Transformationen

- Seien g und h streng monotone Funktionen
- Betrachte transformierte Merkmale

$$\tilde{X} = g(X)$$

$$\tilde{Y} = h(Y)$$

Es gilt

$$\rho_S(\tilde{X}, \tilde{Y}) = \begin{cases} \rho_S(X, Y), & \text{falls } g \text{ und } h \text{ beide wachsend oder beide fallend} \\ -\rho_S(X, Y), & \text{sonst} \end{cases}$$

2. Multivariate EDA

Pearson und Spearman

Invarianz unter Vertauschung von X und Y

$$r_{XY} = r_{YX}$$

$$\rho_S(X, Y) = \rho_S(Y, X)$$


Beweis?

Beispiel

- Körpergröße von Vätern und Söhnen
- positiver Korrelationskoeffizient

Korrelation ist ein Maß für die Stärke eines Zusammenhangs zwischen X und Y , **nicht Kausalität**

The number of movies Dwayne Johnson appeared in
correlates with
Google searches for 'zombies'




Quelle: <https://www.tylervigen.com/spurious-correlations>

2. Multivariate EDA

Pearson und Spearman

1. Sind X und Y in der Abbildung unabhängige Variablen?
2. Welche Werte erwarten Sie für Pearson und Spearman Korrelation?
3. Was ist die Ursache für die Diskrepanz zwischen (1) und (2)?



- Wir brauchen ein Zusammenhangsmaß für nicht-monotone Zusammenhänge!

2. Multivariate EDA

Mutual Information


- Basiert auf Konzepten der Informationstheorie

Definition (Informationsgehalt)

Sei A ein Ereignis mit Eintrittswahrscheinlichkeit p_A .

Dann ist $I_A := -\log_2 p_A$ der Informationsgehalt für das Eintreffen von A .

Maßeinheit: bit



- Je seltener ein Ereignis A , desto größer sein Informationsgehalt I_A
- Logarithmus erleichtert das Rechnen
- Wahl einer anderen Basis verändert nur die Einheit: $\log_2 p_A = \frac{\log_b p_A}{\log_b 2} = c \cdot \log_b p_A$
- $I_A \geq 0$

2. Multivariate EDA

Mutual Information

Definition (Entropie bzw. Shannon-Entropie)

Sei $(\Omega, \mathcal{A}, \mathbb{P})$ ein Wahrscheinlichkeitsraum und X eine diskrete Zufallsvariable mit Wahrscheinlichkeitsfunktion p_k .

Der mittlere Informationsgehalt von X heißt Entropie $H(X)$, genauer:

$$H(X) = \mathbb{E}[I] = - \sum_k p_k \log_2(p_k)$$


- $\mathbb{E}[X]$ bezeichnet den Erwartungswert einer Zufallsvariablen X
- Für $p_k = 0$ interpretieren wir den Ausdruck $0 \log_2(0)$ als $\lim_{p \rightarrow 0} p \log_2(p)$
- Falls $X(\Omega) = \{x_1, \dots, x_d\}$, d.h. X kann d Werte annehmen, dann gilt $H(X) = - \sum_{k=1}^d p_k \log_2(p_k)$

2. Multivariate EDA

Mutual Information

Beispiel

- 2 Klassen: $d = 2$
- $p_1 = \mathbb{P}(X = x_1)$
- $p_2 = \mathbb{P}(X = x_2) = 1 - p_1$



$$H(X) = -(p_1 \log_2 p_1 + p_2 \log_2 p_2) = -(p_1 \log_2 p_1 + (1 - p_1) \log_2 (1 - p_1))$$

2. Multivariate EDA

Mutual Information

Definition (Bedingte Entropie)

Sei $(\Omega, \mathcal{A}, \mathbb{P})$ ein Wahrscheinlichkeitsraum und X, Y zwei diskrete Zufallsvariablen mit gemeinsamer Wahrscheinlichkeitsfunktionen $p_{X,Y}$ und Marginalverteilungen p_X und p_Y .

Die bedingte Wahrscheinlichkeit ist definiert als $p_{X|Y}(x_i|y_j) = \frac{p_{X,Y}(x_i, y_j)}{p_Y(y_j)}$.

Die *Entropie von X bedingt auf $Y = y_j$* ist definiert als

$$H(X|Y = y_j) = - \sum_i p_{X|Y}(x_i|y_j) \log_2(p_{X|Y}(x_i|y_j)).$$

Die *Entropie von X bedingt auf Y* ist definiert als

$$H(X|Y) = \sum_j p_Y(y_j) H(X|Y = y_j).$$

2. Multivariate EDA

Mutual Information

- **Interpretation** (bedingte Entropie): mittlerer Informationsgehalt von X unter der Bedingung, dass Y gegeben ist.

- Es gilt

$$\begin{aligned} H(X|Y) &= \sum_j p_Y(y_j) H(X|Y = y_j) \\ &= - \sum_j p_Y(y_j) \sum_i p_{X|Y}(x_i|y_j) \log_2(p_{X|Y}(x_i|y_j)) \\ &= - \sum_{i,j} p_{X,Y}(x_i, y_j) \log_2 \left(\frac{p_{X,Y}(x_i, y_j)}{p_Y(y_j)} \right) \end{aligned}$$

2. Multivariate EDA

Mutual Information

Definition (Mutual Information)

Sei $(\Omega, \mathcal{A}, \mathbb{P})$ ein Wahrscheinlichkeitsraum und X, Y zwei diskrete Zufallsvariablen. Der Ausdruck

$$I(X; Y) = H(X) - H(X|Y)$$

heißt Mutual Information.

- Interpretation: $I(X; Y)$ gibt die Abnahme des mittleren Informationsgehalts von X durch Kenntnis von Y an.
- **Auf Deutsch:** $I(X; Y)$ misst, wie viel Information Y über X liefert.
- Mutual Information wird auch als Information Gain bezeichnet.

2. Multivariate EDA

Mutual Information

- Y liefert so viel Information über X , wie X über Y
- **Formal (Symmetrie)** $I(X; Y) = I(Y; X)$
- Beweis:


$$\begin{aligned}
 I(X; Y) &= H(X) - H(X|Y) \\
 &= - \sum_i \underbrace{p(x_i)} \log_2(p(x_i)) + \sum_{i,j} p(x_i, y_j) \log_2 \left(\frac{p(x_i, y_j)}{p(y_j)} \right) \\
 &= - \sum_i \left(\sum_j p(x_i, y_j) \right) \log_2(p(x_i)) + \sum_{i,j} p(x_i, y_j) \log_2 \left(\frac{p(x_i, y_j)}{p(y_j)} \right) \\
 &= - \sum_{i,j} p(x_i, y_j) \log_2(p(x_i)) + \sum_{i,j} p(x_i, y_j) \log_2 \left(\frac{p(x_i, y_j)}{p(y_j)} \right) \\
 &= \sum_{i,j} p(x_i, y_j) \left(\log_2 \left(\frac{p(x_i, y_j)}{p(y_j)} \right) - \log_2(p(x_i)) \right) \\
 &\xrightarrow{\text{Symmetrisch in } X \text{ und } Y} \sum_{i,j} p(x_i, y_j) \log_2 \left(\frac{p(x_i, y_j)}{p(x_i)p(y_j)} \right) = I(Y; X)
 \end{aligned}$$

Symmetrisch
in X und Y

2. Multivariate EDA

Mutual Information


- **Symmetrie:** $I(X; Y) = I(Y; X)$
- **Nicht-Negativität:** $I(X; Y) \geq 0$
 - Beweis mit Jensenscher Ungleichung
- **Interpretation**



2. Multivariate EDA

Mutual Information...

- ...kann auch für stetige ZV definiert werden (ersetze W'keitsfunktionen durch Dichtefunktionen)
- ...kann nichtlineare Zusammenhänge messen
- ...ist schwer zu schätzen bei kleinen Stichproben
 - robuste Schätzer wurden in den letzten 20 Jahren entwickelt)



2. Multivariate EDA

Mutual Information

- Einer der bekanntesten Schätzer wurde am Forschungszentrum Jülich entwickelt

PHYSICAL REVIEW E **69**, 066138 (2004)

Estimating mutual information

Alexander Kraskov, Harald Stögbauer, and Peter Grassberger

John-von-Neumann Institute for Computing, Forschungszentrum Jülich, D-52425 Jülich, Germany

(Received 28 May 2003; published 23 June 2004)

We present two classes of improved estimators for mutual information $M(X,Y)$, from samples of random points distributed according to some joint probability density $\mu(x,y)$. In contrast to conventional estimators based on binnings, they are based on entropy estimates from k -nearest neighbor distances. This means that they are data efficient (with $k=1$ we resolve structures down to the smallest possible scales), adaptive (the resolution is higher where data are more numerous), and have minimal bias. Indeed, the bias of the underlying entropy

2. Multivariate EDA


Code in `topic05_multivariate_eda/exercise_mutual_info.py`

Mutual Information (Übung)

- Bestimmen Sie für x und $y \in \{y_1, y_2, \dots, y_5\}$ jeweils die Pearson und Spearman Korrelation und die Mutual Information

```
from scipy.stats import spearmanr, pearsonr
from sklearn.feature_selection import mutual_info_regression
```

```
x = np.linspace(0, 1, 101)
y1 = np.log(10 * x + 0.01)
y2 = np.exp(10 * x)
y3 = np.sin(2 * np.pi * x)
y4 = np.sin(3 * np.pi * x)
y5 = np.random.randn(101)
```



2. Multivariate EDA

Korrelation und Kausalität

- Hohe Werte von Zusammenhangsmaßen können auf kausale Zusammenhänge hinweisen, diese aber nicht begründen
- *Kontrollierte Experimente* können zur Entdeckung von kausalen Zusammenhängen genutzt werden.

Typisch: Merkmal X wird in einem Experiment verändert und man beobachtet die resultierende Änderung von Merkmal Y

- Experimente lassen sich aber in vielen Fällen nicht realisieren (z.B. aus ethischen Gründen) → Entwicklung von Maßen zur Charakterisierung der Richtung eines Zusammenhangs (z.B. *Granger Causality*)


2. Multivariate EDA

Fehlerquellen bei der Beurteilung von Zusammenhängen

- Wesentliche Merkmale (Features) werden nicht berücksichtigt

Beispiel:


- Wortschatz (X) von Kindern
- Körpergröße (Y) von Kindern
- Korrelation (Pearson): $\rho_{XY} = 0.86$
- Welchen kausalen Zusammenhang vermuten Sie?



2. Multivariate EDA

Interpretationsfehler

- Hidden Confounder (Drittvariable)

**Definition Scheinkorrelation:**


Eine Korrelation ohne kausalen Zusammenhang assoziiert ist

Beispiel: Korrelation zw. X und Y .

2. Multivariate EDA

Interpretationsfehler

➤ Indirekte Beziehung




Direkte vs. indirekte Beziehung

2. Multivariate EDA

Interpretationsfehler

➤ Zufällige Korrelation




Data sources: U.S. Office of Management and Budget and Centers for Disease Control & Prevention

Quelle: <https://www.tylervigen.com/spurious-correlations>

2. Multivariate EDA

Interpretationsfehler

➤ Zufällige Korrelation




Quelle: <https://www.tylervigen.com/spurious-correlations>

2. Multivariate EDA

Interpretationsfehler

➤ Zufällige Korrelation




Quelle: <https://www.tylervigen.com/spurious-correlations>

2. Multivariate EDA

Interpretationsfehler

- Verdeckte Korrelation
- Kann auftreten, wenn es Cluster in Stichprobe gibt
- Beispiel
 - Dosierung eines Medikaments vs. Therapieerfolg
 - Cluster: leicht und schwer Erkrankte
 - In jedem Cluster steigt Therapieerfolg mit Dosierung (→ positive Korrelation)
 - Über gesamte Stichprobe ist der Korrelationskoeffizient negativ (Verdeckung der positiven Korrelation in Clustern)



Multivariate EDA

Rückblick

- Was ist ein PC-Plot?
- Wann ist ein PC-Plot hilfreich?
- Was ist der Spearman Korrelationskoeffizient?
- Wie gehen wir mit identischen Werten bei der Berechnung von Rängen um?
- Was ist der Unterschied zwischen Pearson und Spearman Korrelationskoeffizient?
- Ist der Pearson Korrelationskoeffizient invariant bzgl...
 - ... linearen Transformationen?
 - ... monotonen Transformationen?
 - ... Vertauschen von X und Y ?
- Wie können wir nicht-monotone Zusammenhänge messen?
- Was ist Entropie?
- Wie können wir Mutual Information, Entropie und bedingte Entropie grafisch darstellen?
- Folgt aus Korrelation eine Kausalität? Folgt aus Kausalität eine Korrelation?