

Einführung in Data Science

Dimensionsreduktion



Eindimensionale EDA und Visualisierungen

Inhalte

1. Überblick & Grundbegriffe
2. Einführung in Python (NumPy und Pandas)
3. Eindimensionale EDA und Visualisierungen
4. Visualisierungen und mehrdimensionale EDA
5. Mehrdimensionale EDA
- ➡ 6. Dimensionsreduktion: PCA
7. Dimensionsreduktion: MDS, Isomap
8. Clustering: Algorithmen
9. Clustering: Validierung
10. Probeklausur
11. Feature Engineering, datengetriebene Modelle
12. Datengetriebene Modelle
13. Zeitreihen

Überblick &
Grundlagen

Explorative
(Daten-)
Analyse (EDA)

Feature
Engineering &
Modellierung

Heute

1. Wiederholung
2. Dimensionsreduktion
3. Hauptkomponentenanalyse (PCA)

1. Wiederholung

1. Wiederholung

Methoden der multivariaten EDA

1. Visualisierungen → Welche?
 - Scatter Plot
 - Parallel Coordinate (PC-)Plot
2. Zusammenhangsmaße → Welche?
 - Korrelationskoeffizient
 - Pearson
 - Spearman
 - Mutual Information


Jetzt:

3. Dimensionsreduktion

2. Dimensionsreduktion

2. Dimensionsreduktion

Können wir die Dimension der Daten reduzieren ohne (viele) Informationen zu verlieren?




2. Dimensionsreduktion

Beispiel

Temperaturkurven





- 73 spanische Wetterstationen
- Tägliche Temperaturen (365 je Station)
- Wie viele Informationen beinhaltet jede Kurve?
- Wie viele Zahlen („Dimensionen“) brauchen wir, um die 365-dimensionalen Daten zu beschreiben?



2. Dimensionsreduktion

Beispiel




Wie viele Zahlen (Komponenten/Dimensionen) brauchen wir?



2. Multivariate EDA

Warum wollen wir die Dimension reduzieren?

- Explorative Datenanalyse bei vielen Dimensionen schwierig
- Mathematische Gründe!
 - Welches Volumen haben die folgenden Objekte?
 - Was ist der maximale Abstand zwischen zwei Punkten in jedem Objekt?



Allgemein: $V_n = 1$ und $d_n = \sqrt{n}$

2. Multivariate EDA

Warum wollen wir die Dimension reduzieren?

- Allgemein:

$$V_n = 1 \text{ und } d_n = \sqrt{n}$$

- Je höher die Dimension, desto weiter können zwei Punkte entfernt sein
- Außerdem: wenn wir die Seitenlänge verdoppeln, wächst das Volumen exponentiell
 - $V([0,1]) = 1, \quad V([0,2]) = 2$
 - $V([0,1]^2) = 1, \quad V([0,2]^2) = 4 = 2^2$
 - $V([0,1]^n) = 1, \quad V([0,2]^n) = 2^n$
- Statistische Analysen werden schwierig in hohen Dimensionen:

Fluch der Dimensionalität

2. Multivariate EDA

Wie können wir die Dimension reduzieren?

- Spalten (Dimension) weglassen:
 - Schlaf
 - Arbeits- oder Freizeit
- Achtung: Potenziell verlieren wir damit Informationen

	Arbeitszeit	Freizeit	Schlaf
1	7.46	8.54	8
2	7.20	8.80	8
3	7.60	8.40	8
4	7.60	8.40	8
5	7.11	8.89	8
6	6.42	9.58	8
7	5.97	10.03	8
8	4.58	11.42	8
9	11.58	4.42	8
10	10.07	5.93	8

2. Multivariate EDA

Wie können wir die Dimension reduzieren?

- Feature Engineering: Erstelle neue Features



$$\varphi(x_1, x_2) = x_1^2 + x_2^2$$

$$\varphi: \mathbb{R}^2 \rightarrow \mathbb{R}$$

```
import numpy as np
from sklearn.datasets import make_circles

X, y = make_circles(noise=0.1, factor=0.5)
X2 = np.sum(X ** 2, axis=-1)
```

- Beispiel (Temperatur)
 - Minimum und Maximum pro Jahr
 - $\mathbb{R}^{365} \rightarrow \mathbb{R}^2$
- Geht das besser? „Datengetrieben“ statt „manuell“?
 - Ja! PCA



3. Hauptkomponenten- analyse

3. Hauptkomponentenanalyse

- Wie viele Dimensionen brauchen wir **wirklich**, um Daten zu beschreiben?

- Standardrepräsentation:


$$\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = x_1 \begin{pmatrix} 1 \\ 0 \end{pmatrix} + x_2 \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

- Stattdessen finde

- Vektoren v_1, v_2 (gleich für alle Beobachtungen in Datensatz) und
- Skalare s_1, s_2 (unterschiedlich je Beobachtung) sodass

$$\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = s_1 v_1 + s_2 v_2 \approx s_1 v_1$$


- „Meiste“ Informationen in $s_1 v_1$
- Wie finden wir diese Vektoren?
 - Mit der Hauptkomponentenanalyse



3. Hauptkomponentenanalyse

Hauptkomponentenanalyse


- Principal Component Analysis (PCA)
- Neue Komponenten maximieren Varianz
- Neue Komponenten orthogonal zu vorherigen Komponenten



- Komponenten mit vernachlässigbarer Varianz, können weggelassen werden

3. Hauptkomponentenanalyse

Hauptkomponentenanalyse



Quelle: <https://stats.stackexchange.com/a/140579>

3. Hauptkomponentenanalyse

Hauptkomponentenanalyse

- Intuition
 - Die 1. Hauptkomponente maximiert die Varianz
 - Die k . Hauptkomponente ist orthogonal zu allen vorherigen Hauptkomponenten und maximiert die (restliche) Varianz
- Formal

Definition (1. Hauptkomponente)

Gegeben seien zentrierte Beobachtungen $X_1, \dots, X_n \in \mathbb{R}^p$, d.h. $\mathbb{E}[X_i] = 0$. Die erste Hauptkomponente w_1 wird definiert als

$$w_1 = \arg \max_{\|w\|=1} \sum_{i=1}^n \langle X_i, w \rangle^2$$

Warum?

- Misst Winkel zwischen X_i und w
- Je größer, desto ähnlicher die Vektoren

Warum?

3. Hauptkomponentenanalyse

Hauptkomponentenanalyse

- Für die 1. Hauptkomponente gilt

$$w_1 = \arg \max_{\|w\|=1} \sum_{i=1}^n \langle X_i, w \rangle^2.$$

- Sei $\mathbf{X} \in \mathbb{R}^{n \times p}$ die Matrix mit den Beobachtungen $X_1, \dots, X_n$ als Zeilen. Dann gilt

$$w_1 = \arg \max_{\|w\|=1} \|\mathbf{X}w\|^2 = \arg \max_{\|w\|=1} w^T \mathbf{X}^T \mathbf{X} w.$$

- Das Maximum


$$\max_{\|w\|=1} \|\mathbf{X}w\|^2 = \max_{\|w\|=1} w^T \mathbf{X}^T \mathbf{X} w$$

wird als *erklärte Varianz* von w_1 bezeichnet.

3. Hauptkomponentenanalyse

Hauptkomponentenanalyse

- Sei $X \in \mathbb{R}^{n \times p}$ die Matrix mit den Beobachtungen $X_1, \dots, X_n$ als Zeilen und w_1 die 1. Hauptkomponente.
- Wie finden wir für einen Vektor $X \in \mathbb{R}^p$ die „Projektion auf die 1. Hauptkomponente“?
 - $\langle X, w_1 \rangle w_1$
 - Für $X \in \mathbb{R}^p$ gilt $X^T w_1 = \langle X, w_1 \rangle$
 - Damit ist $X w_1 w_1^T$ die Projektion der Beobachtungen auf die 1. Hauptkomponente



3. Hauptkomponentenanalyse

Hauptkomponentenanalyse

Definition (k . Hauptkomponente)

Gegeben sei eine Matrix $\mathbf{X} \in \mathbb{R}^{n \times p}$ mit n zentrierten Beobachtungen in $\mathbb{R}^p$ und die ersten $(k - 1)$ Hauptkomponenten $w_1, \dots, w_{k-1}$.

Weiter sei

$$\mathbf{X}_k = \mathbf{X} - \sum_{i=1}^{k-1} \mathbf{X} w_i w_i^T$$

die Matrix der Residuen.

Die k . Hauptkomponente wird definiert als

$$w_k = \arg \max_{\|w\|=1} \|\mathbf{X}_k w\|^2.$$

Erinnerung:
 $w_1 = \arg \max_{\|w\|=1} \|\mathbf{X} w\|^2$

Projektion von $\mathbf{X}$ auf w_i

3. Hauptkomponentenanalyse

Hauptkomponentenanalyse

- Wie finden wir die Hauptkomponenten?
- Seien $\lambda_1 \geq \dots \geq \lambda_p$ die Eigenwerte der Matrix $\mathbf{X}^T \mathbf{X}$ mit zugehörigen Eigenvektoren $v_1, \dots, v_p$. Dann gilt für $k \in \{1, \dots, p\}$

$$\lambda_k = \max_{\|w\|=1} \|\mathbf{X}w\|^2$$

Woher kennen wir den Ausdruck?

und das Maximum wird von v_k angenommen.

- Die Eigenvektoren entsprechen den Hauptkomponenten (sortiert nach Größe der Eigenwerte) und die Eigenwerte entsprechen der erklärten Varianz je Hauptkomponente.
- Eigenwerte und -vektoren können **effizient** berechnet werden!

3. Hauptkomponentenanalyse

Hauptkomponentenanalyse (Herleitung)

- Warum gilt $\lambda_k = \max_{\|w\|=1} \|\mathbf{X}w\|^2$ und $v_k = \arg \max_{\|w\|=1} \|\mathbf{X}w\|^2$?
- Herleitung 1 (typisch): Optimierung mit Lagrange-Multiplikatoren
- Herleitung 2 (anschaulicher):
 - $C = \mathbf{X}^T \mathbf{X}$ ist symmetrisch, d.h. es gibt eine orthogonale Matrix Q sodass $C = Q\Lambda Q^T$, wobei Λ eine Diagonalmatrix ist mit den (sortierten) Eigenwerte von $\mathbf{X}^T \mathbf{X}$ als Einträgen
 - $\max_{\|w\|=1} w^T \mathbf{X}^T \mathbf{X} w = \max_{\|w\|=1} w^T C w = \max_{\|w\|=1} w^T Q D Q^T w = \max_{\|v\|=1} v^T \Lambda v = \max_{\|v\|=1} \sum_{i=1}^p \lambda_i v_i^2 = \lambda_1$
 - Analog: $\arg \max_{\|w\|=1} w^T \mathbf{X}^T \mathbf{X} w = Q \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} = w_1$

Max. für $v_1 = 1, v_i = 0, i \geq 2$

3. Hauptkomponentenanalyse

Hauptkomponentenanalyse

- Die Hauptkomponenten $w_1, \dots, w_p$ bilden eine Orthonormalbasis des $\mathbb{R}^p$.
- Die Beobachtungen $X_1, \dots, X_n \in \mathbb{R}^p$ lassen sich als Linearkombination der Hauptkomponenten darstellen

$$X_j = \sum_{i=1}^p \langle X_j, w_i \rangle w_i.$$

- Die „meisten“ Informationen stecken in den ersten Hauptkomponenten, d.h. für $d \ll p$ gilt

$$X_j = \sum_{i=1}^p \langle X_j, w_i \rangle w_i \approx \sum_{i=1}^d \langle X_j, w_i \rangle w_i$$

Wie können wir damit die Dimension reduzieren?

$$X = \underbrace{\begin{pmatrix} X^{(1)} \\ \vdots \\ X^{(p)} \end{pmatrix}}_{\mathbb{R}^p} \rightarrow \underbrace{\begin{pmatrix} \langle X, w_1 \rangle \\ \vdots \\ \langle X, w_d \rangle \end{pmatrix}}_{\mathbb{R}^d}$$

3. Hauptkomponentenanalyse



Hauptkomponentenanalyse

- Beobachtungen **müssen** zentriert sein
- Falls sie es nicht sind, zentriere: $\tilde{X}_i = X_i - \bar{X}_n$

3. Hauptkomponentenanalyse

Hauptkomponentenanalyse

- Unten ist derselbe Datensatz dargestellt.
 - Was unterscheidet die beiden Abbildungen
 - In welche Richtung zeigt jeweils die 1. Hauptkomponente?



3. Hauptkomponentenanalyse

Hauptkomponentenanalyse

- Beobachtungen müssen zentriert sein
- Falls sie es nicht sind, zentriere: $\tilde{X}_i = X_i - \bar{X}_n$
- Hauptkomponenten hängen von Skalierung ab
- Standardisierung:

$$\tilde{X}_i = \frac{X_i - \bar{X}_n}{\hat{\sigma}}$$


- Welchen empirischen Mittelwert hat die Stichprobe $\tilde{X}_1, \dots, \tilde{X}_n$ nach der Standardisierung?
- Welche empirische Varianz hat die Stichprobe $\tilde{X}_1, \dots, \tilde{X}_n$ nach der Standardisierung?
- Falls Daten mehrdimensional:
 - Berechne Mittelwert und Standardabweichung je Dimension
 - Für Tabellen/DataFrames: Berechne Größen je **Spalte**
- **Achtung:** Standardisierung kann zu verzerrten Ergebnissen führen und unwichtigen Merkmalen ein großes Gewicht geben!

2. Dimensionsreduktion

Beispiel (Fortsetzung)

Temperaturkurven

- 73 spanische Wetterstationen
- Tägliche Temperaturen (365 je Station)
- Wie viele Informationen beinhaltet jede Kurve?
- Wie viele Zahlen („Dimensionen“) brauchen wir, um die 365-dimensionalen Daten zu beschreiben?







2. Dimensionsreduktion

Code in topic06_pca/
pca_example.py

Beispiel (Fortsetzung)


```
from sklearn.decomposition import PCA  
  
X, y = load_data()  
model = PCA(n_components=10)  
X_proj = model.fit_transform(X)
```

Wie viele Komponenten
benutzen wir, d.h. wie
wählen wir $d \ll p$?
➤ Sodass erklärte
Varianz $\approx 100\%$



FH AACHEN
UNIVERSITY OF APPLIED SCIENCES

Second principal component



2. Dimensionsreduktion

Code in topic06_pca/
pca_generate_data.py



Beispiel (Fortsetzung)

- Wir können mit der PCA auch neue Daten erzeugen → Wie
- Dimensionsreduktion:

$$\mathbb{R}^p \ni X = \begin{pmatrix} X^{(1)} \\ \vdots \\ X^{(p)} \end{pmatrix} \rightarrow \begin{pmatrix} \langle X, w_1 \rangle \\ \vdots \\ \langle X, w_d \rangle \end{pmatrix} \in \mathbb{R}^d$$

- Andersrum:

$$\mathbb{R}^d \ni \begin{pmatrix} \alpha_1 \\ \vdots \\ \alpha_d \end{pmatrix} \rightarrow \sum_{i=1}^d \alpha_i w_i \in \mathbb{R}^p$$



3. Hauptkomponentenanalyse

Code in topic06_pca/
pca_exercise.py



Hauptkomponentenanalyse

Übung

1. Laden Sie den Iris Datensatz mit scikit-learn.

```
from sklearn.datasets import load_iris
```

2. Reduzieren Sie die Dimension des Datensatzes von 4 auf 2.
3. Visualisieren Sie die beiden Hauptkomponenten und die Projektion der Daten (kodieren Sie die Art der Pflanze farblich).
4. Wie können die beiden Hauptkomponenten interpretiert werden?



Multivariate EDA

Rückblick

- Warum wollen wir die Dimension von Daten reduzieren?
- Warum können wir die Dimension von Daten reduzieren?
- Wie können wir die Dimension von Daten reduzieren?
- Was ist die Idee hinter der PCA?
- In welchem Verhältnis stehen Hauptkomponenten?
- Was ist die erklärte Varianz? Wofür nutzen wir sie?
- Wie können wir Hauptkomponenten und erklärte Varianz effizient berechnen?
- Wie können wir mit der PCA die Dimension reduzieren?
- Wie können wir mit der PCA neue Daten generieren?