

Einführung in Data Science

Clustering: Algorithmen

Clustering Algorithmen

Inhalte

1. Überblick & Grundbegriffe
2. Einführung in Python (NumPy und Pandas)
3. Eindimensionale EDA und Visualisierungen
4. Visualisierungen und mehrdimensionale EDA
5. Mehrdimensionale EDA
6. Dimensionsreduktion: PCA
7. Dimensionsreduktion: MDS, Isomap
- ➡ 8. Clustering: Algorithmen
9. Clustering: Validierung
10. Probeklausur
11. Feature Engineering, datengetriebene Modelle
12. Datengetriebene Modelle
13. Zeitreihen

Überblick &
Grundlagen

Explorative
(Daten-)
Analyse (EDA)

Feature
Engineering &
Modellierung

Heute

1. Wiederholung
2. Clustering
3. Partitionierendes Clustering
4. Hierarchisches Clustering


1. Wiederholung

1. Wiederholung

Multidimensional Scaling (MDS)

- Gegeben: Paarweise Distanzen zwischen n Objekten $D = (d_{ij})_{i,j=1}^n$
- Gesucht: Datenmatrix $\mathbf{X}$, mit Koordinaten für jedes der n Objekte, sodass die Objekte die paarweisen Distanzen aus D haben

Ziel Start	Barcelona	Granada	La Coruña	Madrid	Sevilla	Valencia
Barcelona	0	680	900	500	830	300
Granada	680	0	790	360	210	380
La Coruña	900	790	0	510	680	800
Madrid	500	360	510	0	390	300
Sevilla	830	210	680	390	0	540
Valencia	300	380	800	300	540	0



1. Wiederholung

Multidimensional Scaling (MDS)

- Gegeben: Paarweise Distanzen zwischen n Objekten: $D = (d_{ij})_{i,j=1}^n$
- Gesucht: Datenmatrix $\mathbf{X}$ mit Abständen aus D

Algorithmus:

1. Quadriere Einträge der Matrix D , d.h. $\tilde{D} = (d_{ij}^2)_{i,j=1}^n$

2. Berechne Matrix $B \in \mathbb{R}^{n \times n}$ für $H = I - \frac{1}{n} \mathbf{1} \cdot \mathbf{1}^T$ als

$$B = -\frac{1}{2} H \tilde{D} H$$

3. Konstruiere $\mathbf{X}$ durch Eigenwertzerlegung von B (Eigenwerte $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$ mit Eigenvektoren $v_1, \dots, v_p$)

$$\mathbf{X} = V \Lambda^{\frac{1}{2}} = \left(\sqrt{\lambda_1} v_1, \dots, \sqrt{\lambda_p} v_p \right)$$

1. Wiederholung

Multidimensional Scaling (MDS)

➤ Python

```
from sklearn.manifold import MDS

if __name__ == '__main__':
    cities, distance_matrix = get_distance_matrix()


    mds = MDS(n_components=2, dissimilarity="precomputed", n_init=100, max_iter=500)
    coordinates = mds.fit_transform(distance_matrix)
```

- Wie wählen wir die Dimension p der Daten?
- MDS: Anteil der erklärten Distanzen (Proportion of Distance Matrix Explained – PDME)

$$\text{PDME}(j) = \frac{\lambda_j}{\sum_{i=1}^n |\lambda_i|}$$

1. Wiederholung

Isomap



- Gegeben: Datenmatrix $\mathbf{X} \in \mathbb{R}^{n \times p}$
- Gesucht: Niedrigdimensionale Projektion $\tilde{\mathbf{X}} \in \mathbb{R}^{n \times d}$ mit $d < p$

Algorithmus:

1. Ermittle Nachbarschaftsgraph
2. Ermittle paarweise Distanzen zwischen Punkten auf dem Graph
3. Wende MDS auf Matrix D der paarweisen Distanzen an

1. Wiederholung

Methoden der multivariaten EDA

1. Visualisierungen

- Scatter Plot
- Parallel Coordinate (PC-)Plot

2. Zusammenhangsmaße

- Korrelationskoeffizient (Pearson, Spearman)
- Mutual Information

3. Dimensionsreduktion → Welche?

- PCA
- MDS, Isomap

Jetzt:

4. Clustering (auch: Clusteranalyse)

2. Clustering

2. Clustering

Clusteranalyse

- Methoden, die die Identifizierung von Gruppen (Clustern) ähnlicher Datenpunkte in einem Datensatz ermöglichen

Clustering

- Partition (Einteilung) der Datenpunkte in Gruppen

Viele Clustering-Verfahren existieren und unterscheiden sich

- in der Definition von Ähnlichkeit
- in der Definition von Gruppen (Clustern)
- Im algorithmischen Vorgehen

2. Clustering


Clustering

Warum wollen wir Daten clustern?

➤ Um Aussagen über Gruppen in den Daten zu machen (z.B. über Kundensegmente)

➤ Beispiel

- Daten: Alter und jährliches Einkommen von 201 Kunden
- Ziel: Zusammenfassen der Kunden zu Segmenten




2. Clustering

Clustering



Übung

Arbeiten Sie zu zweit.

1. Wie viele und welche Cluster enthält der Datensatz?
2. Wenn Sie mehrere Clusterings finden: Welches ist richtig? Welches ist falsch?



1. s. rechts
2. Es kommt darauf an




2. Clustering

Clustering

- Cluster-Verfahren finden immer Cluster in den Daten
- Verschiedene Verfahren liefern unterschiedliche Cluster
- Cluster-Verfahren basieren auf unterschiedlichen (teils impliziten) Annahmen
- Wie Partitionen bewertet werden können (z.B. sinnvoll/nicht sinnvoll) ist aktuelles und (im Allgemeinen) ungelöstes Forschungsproblem
- Wir betrachten: partitionierende und hierarchische Cluster-Verfahren

Überblick & Grundbegriffe
1. Was ist Data Science?

Modellierung



$f = -1$

$f = +1$

$f = ?$

Quelle: <https://home.work.caltech.edu/telecourse.html>

© FH AACHEN UNIVERSITY OF APPLIED SCIENCES 24. März 2025 | 19


3. Partitionierendes Clustering: k-Means

3. Partitionierendes Clustering

Partitionierendes Clustering

- Wähle k Clusterzentren
- Update Clusterzentren iterativ
- Wichtige partitionierende Verfahren
 - k -Means (und Varianten)
 - k -Means++
 - k -Median
 - k -Medoids
 - EM-Clustering
- Anzahl der Clusterzentren vorgegeben

≠ k -nearest
neighbors (nicht
verwechseln)



3. Partitionierendes Clustering

k-Means Clustering

➤ Gegeben:

- Daten $X_1, \dots, X_n$
- Anzahl der Cluster k

➤ Gesucht: Cluster $C_1, \dots, C_k$

➤ Idee: Ein Clustering ist gut, wenn die Abstände der Punkte in einem Cluster klein sind

- Definiere *Intra-Cluster-Variation*

Cluster sollen Daten partitionieren, d.h.

- $C_1 \cup \dots \cup C_k = \{X_1, \dots, X_n\}$
- $C_i \cap C_j \forall i \neq j$

$$W(C_i) = \frac{1}{|C_i|} \sum_{x,y \in C_i} \|x - y\|^2$$

Quadrierter
euklidischer
Abstand

- Wir suchen Cluster, die $W(C_k)$ minimieren

$$\arg \min_{C_1, \dots, C_k} \sum_{i=1}^k W(C_i)$$

Summe über
alle Paare in
Cluster

3. Partitionierendes Clustering

***k*-Means Clustering**

- Gegeben:
 - Daten $X_1, \dots, X_n$
 - Anzahl der Cluster k
- Gesucht: Cluster $C_1, \dots, C_k$
- Optimierungsproblem:

$$\arg \min_{C_1, \dots, C_k} \sum_{i=1}^k \frac{1}{|C_i|} \sum_{x, y \in C_i} \|x - y\|^2$$

- Das Optimierungsproblem ist schwierig, deshalb nutzen wir einen iterativen Algorithmus, der eine (aber nicht zwangsläufig die beste) Lösung liefert.

3. Partitionierendes Clustering

k-Means Clustering

➤ Gegeben:

- Daten $X_1, \dots, X_n$
- Anzahl der Cluster k

➤ Gesucht: Cluster $C_1, \dots, C_k$

➤ **k**-Means Algorithmus:

1. Wähle k zufällige Clusterzentren $m_1^{(1)}, \dots, m_k^{(1)}$ aus den Daten

2. Wiederhole bis Stoppkriterium erreicht:

3. Berechne Cluster $C_i^{(t)} = \left\{ X_j : \left\| X_j - m_i^{(t)} \right\|^2 = \min_{i^*=1, \dots, k} \left\| X_j - m_{i^*}^{(t)} \right\|^2 \right\}$

4. Berechne Clusterzentren $m_i^{(t+1)} = \frac{1}{|C_i^{(t)}|} \sum_{X_j \in C_i^{(t)}} X_j$

Was passiert hier?

- Schritt 3 ordnet jeden Punkt dem nächstgelegenen Clusterzentrum zu
- Schritt 4 berechnet anschließend die Clusterzentren neu

3. Partitionierendes Clustering

***k*-Means Clustering**

$$\arg \min_{C_1, \dots, C_k} \sum_{i=1}^k \frac{1}{|C_i|} \sum_{x, y \in C_i} \|x - y\|^2$$

- Wie hängt *k*-Means mit unserer Zielfunktion zusammen?
- Es gilt

$$\frac{1}{|C_i|} \sum_{x, y \in C_i} \|x - y\|^2 = 2 \sum_{x \in C_i} \|x - m_i\|^2 \quad \boxed{1}$$

wobei $m_i = \frac{1}{|C_i|} \sum_{x \in C_i} x$ das Clusterzentrum bezeichnet

- Antwort: Schritt 3 minimiert die rechte Seite der Gleichung (und dadurch auch die linke Seite, also das Optimierungsproblem)

3. Partitionierendes Clustering

k-Means Clustering

$$\frac{1}{|C_i|} \sum_{x,y \in C_i} \|x - y\|^2 = 2 \sum_{x \in C_i} \|x - m_i\|^2$$

Beweis von (1)

- Für Skalarprodukte gilt die binomische Formel $\|x - y\|^2 = \|x\|^2 - 2\langle x, y \rangle + \|y\|^2$
- Damit folgt

$$\begin{aligned}
 \frac{1}{|C_i|} \sum_{x,y \in C_i} \|x - y\|^2 &= \frac{1}{|C_i|} \sum_{x,y \in C_i} \|(x - m_i) - (y - m_i)\|^2 \\
 &= \frac{1}{|C_i|} \sum_{x,y \in C_i} \|x - m_i\|^2 - 2\langle x - m_i, y - m_i \rangle + \|y - m_i\|^2 \\
 &= \underbrace{\frac{1}{|C_i|} \sum_{x,y \in C_i} \|x - m_i\|^2}_{\sum_{x \in C_i} \|x - m_i\|^2} + \underbrace{\frac{1}{|C_i|} \sum_{x,y \in C_i} \|y - m_i\|^2}_{\sum_{y \in C_i} \|y - m_i\|^2} - \underbrace{\frac{2}{|C_i|} \sum_{x,y \in C_i} \langle x - m_i, y - m_i \rangle}_0
 \end{aligned}$$

3. Partitionierendes Clustering

k-Means Clustering

$$\frac{1}{|C_i|} \sum_{x,y \in C_i} \|x - y\|^2 = 2 \sum_{x \in C_i} \|x - m_i\|^2$$

Beweis von (1)

➤ Noch zu zeigen: $\sum_{x,y \in C_i} \langle x - m_i, y - m_i \rangle = 0$


$$\sum_{x,y \in C_i} \langle x - m_i, y - m_i \rangle = \underbrace{\sum_{x,y \in C_i} \langle x, y \rangle}_{|C_i|^2 \|m_i\|^2} - \underbrace{\sum_{x,y \in C_i} \langle m_i, y \rangle}_{|C_i|^2 \|m_i\|^2} - \underbrace{\sum_{x,y \in C_i} \langle x, m_i \rangle}_{|C_i|^2 \|m_i\|^2} + \underbrace{\sum_{x,y \in C_i} \langle m_i, m_i \rangle}_{|C_i|^2 \|m_i\|^2} = 0$$

$$\sum_{x,y \in C_i} \langle x, y \rangle = \left\langle \sum_{x \in C_i} x, \sum_{y \in C_i} y \right\rangle = \langle |C_i| m_i, |C_i| m_i \rangle = |C_i|^2 \langle m_i, m_i \rangle = |C_i|^2 \|m_i\|^2$$

3. Partitionierendes Clustering

k-Means Clustering

1. Zufällige Clusterzentren
 - Oben links
2. Ordne jeden Punkt einem Zentrum zu (blau, orange, grün)
3. Update Clusterzentren (rot)
 - 1. Iteration: oben rechts
 - 2. Iteration: unten links
 - 3. Iteration: unten rechts




3. Partitionierendes Clustering


k -Means Clustering

Was repräsentieren die Punkte?

- Heinrichs, F. (2024). *Algorithmen, Zufall, Unsicherheit- und Pizza!: Wie Mathematik uns hilft, alltägliche Entscheidungen zu treffen*. Springer-Verlag.




Die Antwort
gibt's hier!



3. Partitionierendes Clustering

k-Means Clustering





Quelle: <https://de.wikipedia.org/wiki/K-Means-Algorithmus>

3. Partitionierendes Clustering

k-Means Clustering

- Oft kombiniert mit Dimensionsreduktion
 - z.B. PCA






3. Partitionierendes Clustering

Code in topic08_clustering/
k_means.py

k-Means Clustering (Python)

- Implementiert in scikit-learn

```
from sklearn.cluster import KMeans  
  
X, y = load_data()  
model = KMeans(n_clusters=k)  
model.fit(X_proj)  
pred = model.predict(X_proj)
```



3. Partitionierendes Clustering

Code in `topic08_clustering/
k_means_exercise.py`

***k*-Means Clustering**

Übung


1. Laden Sie die spanischen Temperaturkurven (`data/temperature_data.csv`)
2. Reduzieren Sie die Dimension der Daten mit der PCA auf $p = 2$.
3. Wenden Sie *k*-Means für $k = 4$ auf die Daten an und visualisieren die Cluster.
4. Wenden Sie *k*-Means für $k = 2$ auf die Daten und anschließend auf die sich ergebenden Cluster an. Visualisieren Sie das Ergebnis. (Sie sollten so auch 4 Cluster erhalten).
5. Wie unterscheiden sich die Clusterings in 3. und 4.? Warum?

Hinweis: Den Code für 1. – 3. finden Sie in `topic08_clustering/k_means_exercise.py`

3. Partitionierendes Clustering

Code in topic08_clustering/
k_means_exercise.py

k-Means Clustering





3. Partitionierendes Clustering

k-Means Clustering

Sind die Cluster gut?

- *k*-Means nutzt euklidische Distanz
- Alter 30 und 60 näher als Einkommen 50 000 und 50 031



3. Partitionierendes Clustering

***k*-Means Clustering**

Wichtigste Schwachstellen

- *k*-Means Clustering hängt von zufälliger Anfangsinitialisierung ab
 - Findet lokale Minima der Zielfunktion, nicht zwangsläufig globales Minimum
- Clusteranzahl *k* muss zu Beginn festgelegt werden
 - Verschiedene Werte liefern unterschiedliche Cluster
- Keine Möglichkeit Ausreißer in den Daten zu erkennen und getrennt zu behandeln
- **Empfehlung:** Führen Sie *k*-Means mit unterschiedlichen zufälligen Initialisierungen durch und wählen das Ergebnis mit dem kleinsten Wert für die Zielfunktion

3. Partitionierendes Clustering

k-Means Clustering

- Finale Ergebnisse von 6 Wiederholungen von *k*-Means
- Zahlen über den Abbildungen sind die summierten Intra-Cluster Variationen (Zielfunktion)

Übung

Arbeiten Sie zu zweit.

1. Welches Clustering würden Sie wählen?
2. Wie viele lokale Minima der Optimierungsfunktion sehen Sie hier?



3. Partitionierendes Clustering

***k*-Means++**

- *k*-means wählt die initialen Clusterzentren zufällig (gleichverteilt)
 - Ist das sinnvoll? Alternative?
- *k*-means++ wählt Clusterzentren sukzessive mit unterschiedlicher Verteilung
- *k*-medians wählt statt Mittelwert, jeweils den Median pro Cluster
- *k*-medoids erlaubt als Clusterzentren nur Punkte im Datensatz

k-means++ (Initialisierung der Clusterzentren)

1. Wähle (gleichverteilt) ein zufälliges Clusterzentrum $m^{(1)}$ aus Datensatz
2. Für $\ell = 2, \dots, k$:
3. Für jeden Punkt x im Datensatz, bestimme Distanz zu nächstem Clusterzentrum
$$D(x) = \min_{i=1, \dots, \ell-1} \|x - m^{(i)}\|$$
4. Wähle ein neues Clusterzentrum aus der Menge aller (übrigen) Punkte mit Wahrscheinlichkeit proportional zu $D^2(x)$

3. Partitionierendes Clustering

Übung

1. Alleine:

Erstellen Sie eine Klausurfrage zum k -Means Algorithmus.

2. Zu Zweit:


Tauschen Sie sich zu Ihren Klausurfragen aus und versuchen die Fragen zu beantworten.

4. Hierarchisches Clustering

4. Hierarchisches Clustering

Hierarchisches Clustering


- Hierarchie von Clustern
- Von einem Cluster mit n Elementen zu n Clustern mit einem Element
- Darstellung als Dendrogramm
- Erstelle Hierarchie
 - Top-down: 1 Cluster $\rightarrow n$ Cluster
 - Bottom-up: n Cluster $\rightarrow$ 1 Cluster
- Wichtige hierarchische Verfahren
 - Top-down: Bisecting k-Means (iterative Anwendung von 2-Means)
 - Bottom-up: Single linkage, complete linkage, average linkage



4. Hierarchisches Clustering

Dendrogram


- Darstellung einer Clusterhierarchie als Baum
- Jedes Blatt entspricht einem Cluster mit einem Element
- Jeder Knoten entspricht der Vereinigung seiner Kinder
- Die y-Achse beinhaltet oft Informationen über die (Un-)Ähnlichkeit der vereinigten Cluster



4. Hierarchisches Clustering

Bisecting k -Means (top-down)

- Starte mit einem Cluster, dass alle Punkte enthält und wende 2-Means iterativ an
- Welches Cluster sollte geteilt werden?
 - Größtes Cluster
 - Cluster mit „unterschiedlichsten Elementen“ (größte Intra-Cluster-Variation)



4. Hierarchisches Clustering

Code in topic08_clustering/
bisecting_k_means.py

Bisecting *k*-Means (Python)

- Implementiert in scikit-learn


```
from sklearn.cluster import BisectingKMeans
```

```
X, y = load_data()
```

```
# strategy in ["largest_cluster", "biggest_inertia"]
```

```
model = BisectingKMeans(n_clusters=k, bisecting_strategy=strategy)
```


```
pred = model.fit_predict(X)
```



4. Hierarchisches Clustering

Agglomeratives Clustering (bottom-up)


- Starte mit einem Cluster je Punkt und kombiniere iterativ die beiden Cluster mit kleinster Distanz
- Was ist die Distanz zwischen zwei Mengen?
 - Single Linkage: $D(X, Y) = \min_{x \in X, y \in Y} d(x, y)$
 - Complete Linkage: $D(X, Y) = \max_{x \in X, y \in Y} d(x, y)$
 - Average Linkage: $D(X, Y) = \frac{1}{|X| \cdot |Y|} \sum_{x \in X} \sum_{y \in Y} d(x, y)$



4. Hierarchisches Clustering

Single Linkage


- Minimale Inter-Cluster-Unterschiedlichkeit
- Formal: $D(X, Y) = \min_{x \in X, y \in Y} d(x, y)$
- Berechnung:
 - Bestimme alle paarweisen Abstände („Unterschiedlichkeit“) $d(x, y)$ für $x \in X, y \in Y$
 - Bestimme **kleinsten** Abstand



4. Hierarchisches Clustering

Complete Linkage


- Maximale Inter-Cluster-Unterschiedlichkeit
- Formal: $D(X, Y) = \max_{x \in X, y \in Y} d(x, y)$
- Berechnung:
 - Bestimme alle paarweisen Abstände („Unterschiedlichkeit“) $d(x, y)$ für $x \in X, y \in Y$
 - Bestimme **größten** Abstand



4. Hierarchisches Clustering

Average Linkage


- Mittlere Inter-Cluster-Unterschiedlichkeit
- Formal: $D(X, Y) = \frac{1}{|X| \cdot |Y|} \sum_{x \in X} \sum_{y \in Y} d(x, y)$
- Berechnung:
 - Bestimme alle paarweisen Abstände („Unterschiedlichkeit“) $d(x, y)$ für $x \in X, y \in Y$
 - Bestimme **mittleren** Abstand



4. Hierarchisches Clustering

Agglomeratives Clustering (bottom-up)

- Average und Complete Linkage erzeugen i.d.R. ausgewogenere Cluster als Single Linkage




4. Hierarchisches Clustering

Code in topic08_clustering/
agg_clustering.py

Agglomeratives Clustering (Python)

```
from sklearn.cluster import AgglomerativeClustering

X, y = load_data()
# linkage in ['single', 'complete', 'average', 'ward']
model = AgglomerativeClustering(n_clusters=k,
                                linkage=linkage)
pred = model.fit_predict(X)
```



4. Hierarchisches Clustering

Code in `topic08_clustering/agg_clustering_exercise.py`

Agglomeratives Clustering


Übung

1. Laden Sie die spanischen Temperaturkurven (`data/temperature_data.csv`)
2. Reduzieren Sie die Dimension der Daten mit der PCA auf $p = 2$.
3. Wenden Sie für $k = 4$ Cluster die Algorithmen k -Means, Bisecting k -Means und Agglomeratives Clustering (mit single, complete, average und ward linkage) auf die Daten an.
4. Visualisieren Sie die Cluster.
5. Berechnen Sie jeweils die Intra-Cluster-Variation.
6. Welcher Algorithmus führt zum besten Clustering?

Hinweis: Den Code für 1. – 2. finden Sie in `topic08_clustering/k_means_exercise.py`

4. Hierarchisches Clustering

Übersicht – Clustering



Quelle: https://scikit-learn.org/stable/auto_examples/cluster/plot_cluster_comparison.html

4. Hierarchisches Clustering

Annahmen

Welche Annahmen liegen k -Means bzw. dem hierarchischem Clustering zugrunde?

- Ähnliche Punkte liegen nahe zusammen
- Abstandsmaß geeignet, um Ähnlichkeit zu bestimmen
- k -Means:
 - Cluster (tendenziell) kugelförmig
 - Keine Ausreißer in Daten
- Hierarchisches Clustering:
 - Cluster sind hierarchisch (große Cluster setzen sich aus kleineren Clustern zusammen)

Sei ein Datensatz mit Messungen von 50 Frauen und 50 Männern gegeben, die drei Nationalitäten (Deutsch, Japanisch, Amerikanisch) angehören. Die beste Partitionierung mit 2 Clustern liefert die Geschlechter; die beste Partitionierung mit 3 Clustern liefert die Nationalitäten. Welches Clusterverfahren hat diese Partitionierungen vermutlich erzeugt?

- K-Means: Cluster nicht hierarchisch (die 3 Cluster resultieren nicht aus der Teilung der 2 Cluster)

4. Hierarchisches Clustering

Praktische Hinweise

1. Wählen Sie ein passendes Distanzmaß („Unterschiedlichkeitsmaß“)
2. Vorverarbeitung der Daten
 - Überprüfen Sie den Einfluss einer Skalierung der Merkmale auf die Cluster hat
3. Wahl der Cluster
 - Untersuchen Sie den Einfluss der Clusteranzahl auf die Cluster
4. Interpretation der Ergebnisse
 - Die Cluster-Analyse ist häufig der Startpunkt einer Datenanalyse, nicht das Endergebnis

Clustering Algorithmen

Rückblick

- Warum wollen wir Daten clustern?
- Was ist der Unterschied zwischen partitionierenden und hierarchischen Clusterverfahren?
- Welche Größe wollen wir mit k-Means minimieren?
- Wie funktioniert der k-Means Algorithmus?
- Was sind Nachteile von k-Means?
- Wie unterscheidet sich k-Means++ von k-Means?
- Was ist der Unterschied zw. Top-Down und Bottom-Up Clusterverfahren?
 - Was sind jeweils Beispiele?
- Wie erhalten wir aus einem Dendrogramm ein Clustering?
- Wie funktioniert Bisecting k-Means?
- Wie funktioniert agglomeratives Clustering?
- Was ist der Unterschied zwischen Single, Complete und Average Linkage?
- Auf welchen Annahmen basieren die unterschiedlichen Clusterverfahren?
- Welches ist das beste Clusterverfahren?