

Einführung in Data Science

Clustering: Validierung

Clustering Validierung

Inhalte

1. Überblick & Grundbegriffe
2. Einführung in Python (NumPy und Pandas)
3. Eindimensionale EDA und Visualisierungen
4. Visualisierungen und mehrdimensionale EDA
5. Mehrdimensionale EDA
6. Dimensionsreduktion: PCA
7. Dimensionsreduktion: MDS, Isomap
8. Clustering: Algorithmen
- ➡ 9. Clustering: Validierung
10. Probeklausur
11. Feature Engineering, datengetriebene Modelle
12. Datengetriebene Modelle
13. Zeitreihen

Überblick &
Grundlagen

Explorative
(Daten-)
Analyse (EDA)

Feature
Engineering &
Modellierung

Heute

1. Wiederholung
2. Validierung von Clustering

1. Wiederholung

1. Wiederholung

Clusteranalyse

- Methoden, die die Identifizierung von Gruppen (Clustern) ähnlicher Datenpunkte in einem Datensatz ermöglichen
- Aussagen über Gruppen in den Daten zu machen (z.B. über Kundensegmente)

Clustering

- Partition (Einteilung) der Datenpunkte in Gruppen

Ansätze

- Partitionierende Verfahren: Beginne mit k Clusterzentren und passe sie iterativ an
 - k -means, k -means++
- Hierarchische Verfahren: Erstelle Hierarchie von Clustern
 - Bottom-Up, Top-Down

1. Wiederholung

***k*-Means Clustering**

➤ Gegeben:

- Daten $X_1, \dots, X_n$
- Anzahl der Cluster k

➤ Gesucht: Cluster $C_1, \dots, C_k$

➤ *k*-Means Algorithmus:

1. Wähle k zufällige Clusterzentren $m_1^{(1)}, \dots, m_k^{(1)}$ aus den Daten

2. Wiederhole bis Stoppkriterium erreicht:


3. Berechne Cluster $C_i^{(t)} = \left\{ X_j: \left\| X_j - m_i^{(t)} \right\|^2 = \min_{i^*=1, \dots, k} \left\| X_j - m_{i^*}^{(t)} \right\|^2 \right\}$

4. Berechne Clusterzentren $m_i^{(t+1)} = \frac{1}{|C_i^{(t)}|} \sum_{X_j \in C_i^{(t)}} X_j$

$$\arg \min_{C_1, \dots, C_k} \sum_{i=1}^k \frac{1}{|C_i|} \sum_{x, y \in C_i} \|x - y\|^2$$

1. Wiederholung

k-Means Clustering




Quelle: <https://de.wikipedia.org/wiki/K-Means-Algorithmus>

1. Wiederholung

Hierarchisches Clustering


- Hierarchie von Clustern
- Von einem Cluster mit n Elementen zu n Clustern mit einem Element
- Darstellung als Dendrogramm
- Erstelle Hierarchie
 - Top-down: 1 Cluster $\rightarrow n$ Cluster
 - Bottom-up: n Cluster $\rightarrow$ 1 Cluster
- Wichtige hierarchische Verfahren
 - Top-down: Bisecting k-Means (iterative Anwendung von 2-Means)
 - Bottom-up: Single linkage, complete linkage, average linkage



1. Wiederholung

Bisecting k -Means (top-down)


- Starte mit einem Cluster, dass alle Punkte enthält und wende 2-Means iterativ an
- Teile:
 - Größtes Cluster
 - Cluster mit „unterschiedlichsten Elementen“ (größte Intra-Cluster-Variation)



1. Wiederholung

Agglomeratives Clustering (bottom-up)

- Starte mit einem Cluster je Punkt und kombiniere iterativ die beiden Cluster mit kleinster Distanz
- Was ist die Distanz zwischen zwei Mengen?
 - Single Linkage: $D(X, Y) = \min_{x \in X, y \in Y} d(x, y)$
 - Complete Linkage: $D(X, Y) = \max_{x \in X, y \in Y} d(x, y)$
 - Average Linkage: $D(X, Y) = \frac{1}{|X| \cdot |Y|} \sum_{x \in X} \sum_{y \in Y} d(x, y)$



2. Validierung von Clustering


2. Cluster Validierung

Clustering

- **Wiederholung:** Cluster-Verfahren finden immer Cluster in den Daten
- Welches Clustering ist sinnvoll? Welches nicht?
- Clustervalidierungsverfahren bewerten Qualität von Clusterings
 - Das ermöglicht Wahl von Hyperparametern!
- Clustervalidierung
 - Viele Verfahren publiziert
 - Keine endgültige Empfehlung für eine Methode möglich [1]
 - Aktueller Forschungsgegenstand

Überblick & Grundbegriffe 1. Was ist Data Science?

Modellierung



Quelle: <https://home.work.caltech.edu/telecourse.html>

© FH AACHEN UNIVERSITY OF APPLIED SCIENCES

24. März 2025 | 19

Hyperparameter: Parameter, die das Modell beschreiben, aber nicht geschätzt werden müssen


- k -Means: Anzahl der Cluster k
- k -Means: Nicht Clusterzentren $m^{(1)}, \dots, m^{(k)}$

[1] Everitt BS, Landau S, Leese M, Stahl D. Cluster Analysis, Wiley 2011


2. Cluster Validierung

Clustering

1. Können Sie Cluster in den dargestellten Daten finden?
2. Wie viele Cluster haben Sie identifiziert?



Zufällige Daten (gleichverteilt)



k -Means (6 Cluster)

2. Cluster Validierung

Clustering

1. Statistische Tests auf Abwesenheit von Clustern

- Möglich, aber unüblich
- Nullhypothese z.B. H_0 : Daten sind gleichverteilt

Daten sind nicht
gleichverteilt
⇔ Es gibt Cluster

➔ 2. Externe Clustervalidierung

- Kriterien, die auf externen Informationen über die „wahre“ Clusterzugehörigkeit basieren

3. Interne Clustervalidierung

- Kriterien, die nur auf den Daten basieren

- Wenn es eine wahre Gruppenzugehörigkeit gibt, sprechen wir in der Regel von Klassifikation und nicht von Clustering.
- Clustering ist explorativ
- Die Zugehörigkeit wird nicht für den Algorithmus benutzt, nur zur Bewertung der Cluster und ist vergleichbar mit den Testdaten beim supervised learning

2. Cluster Validierung

Externe Clustervalidierung (nutzt externe Information)

➤ Es gibt viele Ansätze. Wir betrachten: *Purity* und *Mutual Information*

➤ Purity misst die Reinheit von Clustern

➤ $C_1, \dots, C_k$ Cluster

➤ $T_1, \dots, T_k$ Wahre Cluster (*ground truth*)

➤ $n_i = |C_i|$ Anzahl der Elemente in Cluster i

➤ $\text{purity}_i = \frac{1}{n_i} \max_{j=1}^k |C_i \cap T_j|$ Reinheit des Clusters i

➤ $\text{purity}_i = 1$, wenn C_i nur Punkte eines Clusters T_j enthält.

➤
$$\text{purity} = \sum_{i=1}^k \frac{n_i}{n} \text{purity}_i = \frac{1}{n} \sum_{i=1}^k \max_{j=1}^k |C_i \cap T_j|$$

➤ $\text{purity} = 1$, wenn alle Cluster C_i nur Punkte eines wahren Clusters enthalten

2. Cluster Validierung

Externe Clustervalidierung (nutzt externe Information)

- **Purity** misst die Reinheit von Clustern

$$\text{purity} = \sum_{i=1}^k \frac{n_i}{n} \text{purity}_i = \frac{1}{n} \sum_{i=1}^k \max_{j=1}^k |C_i \cap T_j|$$

- Mit welchem Vorgehen erhalten Sie *immer* eine Purity von 1?
 1. Falls es nur ein Cluster T gibt: Mit jedem Vorgehen
 2. Ansonsten: Ein Cluster je Punkt

2. Cluster Validierung

Externe Clustervalidierung (nutzt externe Information)

- **Mutual Information** misst die Ähnlichkeit zwischen Partitionen C und T

$$I(C, T) = \sum_{i,j} p_{ij} \log_2 \left(\frac{p_{ij}}{p_{C_i} p_{T_j}} \right)$$

mit

- $p_{ij} = \frac{|C_i \cap T_j|}{n}$ (Wahrscheinlichkeit, dass ein Punkt zu C_i und T_j gehört)
- $p_{C_i} = \frac{|C_i|}{n}$ (Wahrscheinlichkeit, dass ein Punkt zu C_i gehört)
- $p_{T_j} = \frac{|T_j|}{n}$ (Wahrscheinlichkeit, dass ein Punkt zu T_j gehört)
- Mutual Informationen kennen wir bereits von der multivariaten EDA
- Je Größer die Mutual Information, desto ähnlicher sind C und T

2. Cluster Validierung

Interne Clustervalidierung (basiert nur auf Daten)

- Häufig die einzige Möglichkeit (ground truth normalerweise nicht bekannt)
- In der Praxis am weitesten verbreitet
- Es gibt viele Ansätze. Wir betrachten:
 - ➡ ➤ *Silhouette/Silhouette Plots*
 - *Prediction Strength*

2. Cluster Validierung

Silhouette [1]

- Silhouettenindex
 - Misst wie gut ein einzelner Punkt geclustert wurde
 - Genauer: Misst Ähnlichkeit eines Punktes zu den anderen Punkten im Cluster (**Kohäsion**) in Relation zur Unähnlichkeit mit Punkten anderer Cluster (**Separation**)
- Silhouettenplot
 - Visuelle Darstellung der Silhouettenindizes für den gesamten Datensatz
 - Sortiert nach Clusterzugehörigkeit

[1] Rousseeuw, P.J. Journal of Comp. Appl. Math. 20, 53-65 (1987)

2. Cluster Validierung

Silhouettenindex

- Seien $C_1, \dots, C_k$ Cluster
- Sei $x_i \in C_j$ und $d(x_i, x_j)$ der (euklidische) Abstand zwischen x_i und x_j
- Kohäsion (misst Ähnlichkeit)


- Mittlere Distanz zwischen x_i und allen anderen Punkten in Cluster C_j

$$a(x_i) = \frac{1}{|C_j| - 1} \sum_{x \in C_j, x \neq x_i} d(x_i, x) \quad \text{für } |C_j| > 1$$

- Separation (misst Unterschiedlichkeit)

- Mittlere Distanz zwischen x_i und allen Punkten im nächsten Cluster

$$b(x_i) = \min_{k \neq j} \frac{1}{|C_k|} \sum_{x \in C_k, x \neq x_i} d(x_i, x)$$



2. Cluster Validierung

Silhouettenindex

- Seien $C_1, \dots, C_k$ Cluster, $x_i \in C_j$ und $d(x_i, x_j)$ der (euklidische) Abstand zwischen x_i und x_j
- Seien $a(x_i)$ die Kohäsion und $b(x_i)$ die Separation von x_i
- Der Silhouettenindex ist definiert als

$$s(x_i) = \begin{cases} 1 - \frac{a(x_i)}{b(x_i)}, & \text{falls } |C_j| > 1 \text{ und } a(x_i) < b(x_i) \\ 0, & \text{falls } |C_j| = 1 \text{ oder } a(x_i) = b(x_i) \\ \frac{b(x_i)}{a(x_i)} - 1, & \text{falls } |C_j| > 1 \text{ und } a(x_i) > b(x_i) \end{cases}$$

$$= \frac{b(x_i) - a(x_i)}{\max\{a(x_i), b(x_i)\}}$$

Gut: x_i ähnlicher zu Punkten in Cluster als zu Punkten anderer Cluster

Nicht eindeutig

Schlecht: x_i liegt im Mittel näher an Punkten eines anderen Clusters

- Wertebereich: $s(x_i) \in [-1, 1]$

Gegeben seien zwei Cluster C_1, C_2 und $x_i \in C_1$. Wie verändert sich $s(x_i)$, wenn x_i Cluster C_2 zugeordnet wird?

- $s(x_i) \rightarrow -s(x_i)$

2. Cluster Validierung

Mittlerer Silhouettenindex

- Für Cluster C_j : $\bar{s}_j = \frac{1}{|C_j|} \sum_{x \in C_j} s(x)$ ← „average silhouette width“
bewertet einzelne Cluster
- Für alle Daten: $\bar{s} = \frac{1}{n} \sum_{i=1}^n s(x_i)$ ← „silhouette score“
bewertet alle Cluster


Silhouettenplots

- Darstellung der Silhouettenindizes nach Cluster gruppiert in absteigender Größe
- Erlauben visuelle Einschätzung der Clusterqualität

2. Cluster Validierung

Silhouettenplots


- Beispiel: k -Means Clustering eines synthetischen Datensatzes



2. Cluster Validierung

Silhouettenplots


- Beispiel: k -Means Clustering eines synthetischen Datensatzes



2. Cluster Validierung

Silhouettenplots


- Beispiel: k -Means Clustering eines synthetischen Datensatzes



2. Cluster Validierung

Silhouettenplots


- Beispiel: k -Means Clustering eines synthetischen Datensatzes



2. Cluster Validierung

Silhouettenplots

- Beispiel: k -Means Clustering eines synthetischen Datensatzes






- Score maximal für $k = 4$

2. Cluster Validierung

Silhouettenplots

- Die Daten wurden mit agglomerativem Clustern (single linkage) geclustert.
- Warum zeigt der Silhouette Score nicht die richtige Clusteranzahl an?

Silhouettenplots und Silhouette Score nehmen Cluster als (tendenziell) kugelförmig an. Das ist hier nicht der Fall



2. Cluster Validierung

Übung

1. Alleine:

Erstellen Sie eine Klausurfrage zu Silhouettenindex/-plots.

2. Zu Zweit:

Tauschen Sie sich zu Ihren Klausurfragen aus und versuchen die Fragen zu beantworten.

2. Cluster Validierung

Interne Clustervalidierung (basiert nur auf Daten)

- Häufig die einzige Möglichkeit (ground truth normalerweise nicht bekannt)
- In der Praxis am weitesten verbreitet
- Es gibt viele Ansätze. Wir betrachten:
 - *Silhouette/Silhouette Plots*
 -  ➤ *Prediction Strength*

2. Cluster Validierung

Prediction Strength [1]

- Idee: Clusterqualität ist hoch, wenn Clusterzugehörigkeit auf anderen Realisierungen der Daten zuverlässig vorhergesagt werden kann.
 - Vorgehen entspricht Hyperparameter Tuning bzw. Model Selection im supervised learning
- Algorithmus Beispiel folgt
 1. Teile Daten in Trainings- und Validierungsdaten auf.
 2. Wende dasselbe Clusterverfahren auf beide Datensätze an.
 3. Ermittle für alle Punkte in den Validierungsdaten, das Cluster gemäß Trainingsdaten.
 4. Bestimme für jedes „Validierungs“-Cluster den Anteil p aller Paare von Punkten, die im selben „Trainings“-Cluster wären.
 5. Der kleinste Wert von p über alle Cluster heißt *prediction strength*.

[1] Tibshirani et al. J. Comput. Graph. Stat. 14, 511-528, 2005




2. Cluster Validierung

Code in `topic09_cluster_validation/prediction_strength.py`

Prediction Strength - Beispiel

1. Teile Daten in Trainings- und Validierungsdaten auf.

- Sei $\mathcal{D} = \{x_1, \dots, x_n\}$ der Datensatz
- Unterteile $\mathcal{D}$ in Trainings- und Validierungsdaten ($\mathcal{D}_{\text{train}}$ und $\mathcal{D}_{\text{val}}$)
 - $\mathcal{D}_{\text{train}} \cap \mathcal{D}_{\text{val}} = \emptyset$ und $\mathcal{D}_{\text{train}} \cup \mathcal{D}_{\text{val}} = \mathcal{D}$




2. Cluster Validierung

Code in topic09_cluster_validation/
prediction_strength.py


Prediction Strength - Beispiel

2. Wende dasselbe Clusterverfahren auf beide Datensätze an.

➤ Beispiel: Cluster ermittelt mit k -Means für $k = 4$.



- Farbe der Punkte:
Cluster gemäß
jeweiligen Daten
- Farbe der Flächen:
Cluster gemäß
 $\mathcal{D}_{\text{train}}$



2. Cluster Validierung

Code in topic09_cluster_validation/
prediction_strength.py


Prediction Strength - Beispiel

3. Ermittle für alle Punkte in den Validierungsdaten, das Cluster gemäß Trainingsdaten.

Beobachtung

Für $\mathcal{D}_{\text{val}}$ ergeben sich andere
Cluster als für $\mathcal{D}_{\text{train}}$

- Farbe der Punkte: Cluster gemäß jeweiligen Daten
- Farbe der Flächen: Cluster gemäß $\mathcal{D}_{\text{train}}$



2. Cluster Validierung

Code in `topic09_cluster_validation/prediction_strength.py`

Prediction Strength - Beispiel


4. Bestimme für jedes „Validierungs“-Cluster den Anteil p aller Paare von Punkten, die im selben „Trainings“-Cluster wären.

➤ Welchen Wert p hat das...

- blaue Cluster $\rightarrow p = 1$
- orange Cluster $\rightarrow p = 1$
- grüne Cluster $\rightarrow p = 1$
- rote Cluster $\rightarrow p = \frac{4}{10}$

$$n_{\text{rot, val}} = 5, \quad n_{\text{Paare}} = \frac{5 \cdot 4}{2} = 10$$

- Farbe der Punkte: Cluster gemäß jeweiligen Daten
- Farbe der Flächen: Cluster gemäß $\mathcal{D}_{\text{train}}$



5. $\text{prediction strength} = \frac{4}{10}$

2. Cluster Validierung

Prediction Strength - Formal

- Seien $C_1, \dots, C_k$ die Cluster basierend auf $\mathcal{D}_{\text{train}}$
- Seien $A_1, \dots, A_k$ die Cluster basierend auf $\mathcal{D}_{\text{val}}$ und $n' = |\mathcal{D}_{\text{val}}|$
- Sei $M \in \mathbb{R}^{n' \times n'}$ die *Ko-Mitgliedschaftsmatrix* mit

$$M_{ij} = \begin{cases} 1, & \text{falls } \exists k: x_i, x_j \in C_k \\ 0, & \text{sonst} \end{cases}$$

$M_{ij} = 1$, falls die beiden Datenpunkte x_i und x_j aus den Validierungsdaten zum selben Cluster der Trainingsdaten gehören.

- Prediction strength


$$\text{ps}(k) = \min_{\ell=1, \dots, k} \frac{1}{|A_\ell|(|A_\ell| - 1)} \sum_{x_i, x_j \in A_\ell: x_i \neq x_j} M_{ij}$$

Summe über alle Paare im Cluster A_ℓ der Validierungsdaten

2. Cluster Validierung

Prediction Strength


- Wie wird ermittelt zu welchem Cluster ein Punkt x gehören würde?
 - Abhängig vom jeweiligen Clusterverfahren
 - Kodiert Vorstellung davon, was ein Cluster ist
- Beispiel – k -Means
 - Implizite Annahme: Cluster sind tendenziell kugelförmig
 - Clusterzentren definieren Clusterzugehörigkeit
 - Cluster sind Polygone



2. Cluster Validierung

Prediction Strength


- Wie wird ermittelt „zu welchem Cluster ein Punkt x gehören würde?“
 - **Abhängig vom jeweiligen Clusterverfahren**
 - Kodiert Vorstellung davon, was ein Cluster ist
- Beispiel – Agglomeratives Clustering (single linkage)
 - Betrachtet **minimale** (euklidische) Distanz
 - x wird dem Cluster zugeordnet, zu dem es den kleinsten Abstand hat



2. Cluster Validierung

Prediction Strength


- Wie wird ermittelt „zu welchem Cluster ein Punkt x gehören würde?“
 - **Abhängig vom jeweiligen Clusterverfahren**
 - Kodiert Vorstellung davon, was ein Cluster ist
- Beispiel – Agglomeratives Clustering (average linkage)
 - Betrachtet **mittlere** (euklidische) Distanz
 - x wird dem Cluster zugeordnet, zu dem es den kleinsten Abstand hat



2. Cluster Validierung

Prediction Strength

➤ Beispiel – k -Means




Warum ist $ps(1) = 1$?
➤ Jeweils nur 1 Cluster!

2. Cluster Validierung

Prediction Strength

- „Optimale“ Clusteranzahl k entspricht größtem Wert k für den die Prediction Strength maximal ist
- Häufig werden die Daten in 80% Trainings- und 20% Validierungsdaten aufgeteilt
- Alternativ: Cross Validation statt Train-Test-Split



2. Cluster Validierung

Frage

Im Rahmen einer explorativen Datenanalyse clustern Sie Ihre Daten. Wie bewerten Sie Ihre Cluster?

- Mit Methoden der internen oder externen Clustervalidierung? Warum?
- Wann würden Sie Silhouettenindex/-plot gegenüber der Prediction Strength vorziehen? Wann nicht?

Clustering Validierung

Rückblick

- Wozu benutzen wir Clustervalidierungsverfahren?
- Wie unterscheiden sich interne und externe Clustervalidierung?
- Was ist die Purity eines Clusterings?
- In welchem Wertebereich liegt die Purity?
 - Was ist der beste Wert?
- Sind große oder kleine Werte der Mutual Information zu bevorzugen?
- Was misst der Silhouettenindex?
- In welchem Wertebereich liegt der Silhouettenindex?
 - Was ist der beste Wert?
- Wann ist der Silhouettenindex negativ?
 - Was bedeutet das für die Cluster?
- Welche implizite Annahme liegt dem Silhouettenindex zugrunde?
- Wie wird die Prediction Strength bestimmt?
- Warum gilt für die Prediction Strength $ps(1) = 1$?
- Wie erhalten wir mit Hilfe der Prediction Strength die optimale Anzahl Cluster?