

Einführung in Data Science

Feature Engineering & Datengetriebene Modelle

Feature Engineering & Datengetriebene Modelle

Inhalte


1. Überblick & Grundbegriffe
2. Einführung in Python (NumPy und Pandas)
3. Eindimensionale EDA und Visualisierungen
4. Visualisierungen und mehrdimensionale EDA
5. Mehrdimensionale EDA
6. Dimensionsreduktion: PCA
7. Dimensionsreduktion: MDS, Isomap
8. Clustering: Algorithmen
9. Clustering: Validierung
10. Probeklausur
- ➡ 11. Feature Engineering, datengetriebene Modelle
12. Datengetriebene Modelle
13. Zeitreihen

Überblick &
Grundlagen

Explorative
(Daten-)
Analyse (EDA)

Feature
Engineering &
Modellierung

Feature Engineering & Datengetriebene Modelle



Heute

1. Wiederholung
2. Feature Engineering
3. Modellierung

1. Wiederholung

1. Wiederholung

Cluster Validierung


- Bewertung von Clusterings
- Ermöglichen Hyperparameter Tuning
- Welche Ansätze gibt es?
 1. Statistische Tests auf Abwesenheit von Clustern (eher unüblich)
 2. Externe Clustervalidierung
 - basiert auf Informationen über „wahre“ Cluster
 - Beispiele: Purity, Mutual Information
 3. Interne Clustervalidierung
 - Beispiele: Silhouette (Plots), Prediction Strength

$$\text{purity} = \frac{1}{n} \sum_{i=1}^k \max_{j=1}^k |C_i \cap T_j|$$
$$I(C, T) = \sum_{i,j} p_{ij} \log_2 \left(\frac{p_{ij}}{p_{C_i} p_{T_j}} \right)$$

1. Wiederholung

Silhouettenplots


- Beispiel: k -Means Clustering eines synthetischen Datensatzes



1. Wiederholung

Silhouettenplots

- Beispiel: k -Means Clustering eines synthetischen Datensatzes



- Score maximal für $k = 4$

1. Wiederholung

Prediction Strength

- Idee: Clusterqualität ist hoch, wenn Clusterzugehörigkeit auf anderen Realisierungen der Daten zuverlässig vorhergesagt werden kann.
- Algorithmus
 1. Teile Daten in Trainings- und Validierungsdaten auf.
 2. Wende dasselbe Clusterverfahren auf beide Datensätze an.
 3. Ermittle für alle Punkte in den Validierungsdaten, das Cluster gemäß Trainingsdaten.
 4. Bestimme für jedes „Validierungs“-Cluster den Anteil p aller Paare von Punkten, die im selben „Trainings“-Cluster wären.
 5. Der kleinste Wert von p über alle Cluster heißt *prediction strength*.




1. Wiederholung

Code in `topic09_cluster_validation/prediction_strength.py`

Prediction Strength - Beispiel

1. Teile Daten in Trainings- und Validierungsdaten auf.

- Sei $\mathcal{D} = \{x_1, \dots, x_n\}$ der Datensatz
- Unterteile $\mathcal{D}$ in Trainings- und Validierungsdaten ($\mathcal{D}_{\text{train}}$ und $\mathcal{D}_{\text{val}}$)
 - $\mathcal{D}_{\text{train}} \cap \mathcal{D}_{\text{val}} = \emptyset$ und $\mathcal{D}_{\text{train}} \cup \mathcal{D}_{\text{val}} = \mathcal{D}$




1. Wiederholung


Code in topic09_cluster_validation/
prediction_strength.py

Prediction Strength - Beispiel

2. Wende dasselbe Clusterverfahren auf beide Datensätze an.
 3. Ermittle für alle Punkte in den Validierungsdaten, das Cluster gemäß Trainingsdaten.
- Beispiel: Cluster ermittelt mit k -Means für $k = 4$.



- Farbe der Punkte:
Cluster gemäß
jeweiligen Daten
- Farbe der Flächen:
Cluster gemäß
 $\mathcal{D}_{\text{train}}$



1. Wiederholung

Code in topic09_cluster_validation/
prediction_strength.py

Prediction Strength - Beispiel


4. Bestimme für jedes „Validierungs“-Cluster den Anteil p aller Paare von Punkten, die im selben „Trainings“-Cluster wären.

➤ Welchen Wert p hat das...

- blaue Cluster $\rightarrow p = 1$
- orange Cluster $\rightarrow p = 1$
- grüne Cluster $\rightarrow p = 1$
- rote Cluster $\rightarrow p = \frac{4}{10}$

$$n_{\text{rot, val}} = 5, \quad n_{\text{Paare}} = \frac{5 \cdot 4}{2} = 10$$

- Farbe der Punkte: Cluster gemäß jeweiligen Daten
- Farbe der Flächen: Cluster gemäß $\mathcal{D}_{\text{train}}$



5. $\text{prediction strength} = \frac{4}{10}$

1. Wiederholung

Prediction Strength - Formal

- Seien $C_1, \dots, C_k$ die Cluster basierend auf $\mathcal{D}_{\text{train}}$
- Seien $A_1, \dots, A_k$ die Cluster basierend auf $\mathcal{D}_{\text{val}}$ und $n' = |\mathcal{D}_{\text{val}}|$
- Sei $M \in \mathbb{R}^{n' \times n'}$ die *Ko-Mitgliedschaftsmatrix* mit

$$M_{ij} = \begin{cases} 1, & \text{falls } \exists k: x_i, x_j \in C_k \\ 0, & \text{sonst} \end{cases}$$

$M_{ij} = 1$, falls die beiden Datenpunkte x_i und x_j aus den Validierungsdaten zum selben Cluster der Trainingsdaten gehören.

- Prediction strength

$$\text{ps}(k) = \min_{\ell=1, \dots, k} \frac{1}{|A_\ell|(|A_\ell| - 1)} \sum_{x_i, x_j \in A_\ell: x_i \neq x_j} M_{ij}$$

Abhängig von
Clusterverfahren

Summe über alle Paare im Cluster A_ℓ der Validierungsdaten

2. Feature Engineering

2. Feature Engineering

Feature Engineering

- Auf Deutsch: Merkmalskonstruktion
- Prozess, bei dem mithilfe von Domänenwissen Daten transformiert werden, um die daten-getriebene Modellierung zu ermöglichen
- Oft werden neue „Merkmale“ aus den Daten erzeugt (deshalb: Feature Engineering)
- Warum?
 - Repräsentation ist entscheidend

1:  2:  3:  4:  5:  6:  7:  8:  9:  vs.

1	2	3
4	5	6
7	8	9

$$f(k) = \frac{\cos(\pi k) + 1}{2}$$

vs.

1. Konvertierung in Binärdarstellung: $k_{10} \rightarrow k_2$
2. Abbildung auf letzte Ziffer: $k_2 \rightarrow k_2^{(0)}$

- **Feature Engineering „vermittelt“ zwischen Daten und Modellen**

2. Feature Engineering

Feature Engineering

- Feature Engineering ist ...
 - Häufig zeitaufwändig
 - Oft entscheidend für den Erfolg (oder Misserfolg) eines Machine Learning Projekts
 - Domänenspezifisch
 - Bilder: Bildverarbeitung (Computer Vision, CV)
 - Sprache: Natural Language Processing (NLP)
 - Zeitabhängige Daten:
 - Zeitreihenanalyse !!
 - (Digitale) Signalverarbeitung
 - Funktionale Datenanalyse !
 - Complex Event Processing
- Unterschiedliche Daten → Unterschiedliche Features

2. Feature Engineering

Typisches Vorgehen

1. Klassische Methoden der explorativen Datenanalyse (EDA)
 - z.B. Deskriptive Statistik, Dimensionsreduktion, Clustering

Unser Ansatz in der Vorlesung

2. Domänenexperten zu Daten und ihren wichtigsten Eigenschaften befragen

Empfehlung (falls möglich)

3. Selbst zum Domänenexperten für bestimmte Datenarten werden

Spezialisierung!
z.B. während Ausbildung oder Berufsausübung

2. Feature Engineering

Feature Engineering vs. Explorative Datenanalyse

Zielsetzung

- Explorative Datenanalyse: Kennenlernen der Daten und Entwicklung von Fragen
 - Feature Engineering: Daten für die daten-getriebene Modellierung transformieren, um Vorhersagen zu ermöglichen
-

Datengetriebene Modellierung

Erstellung einer mathematischen Beschreibung mithilfe von Daten

Beispiele: Machine Learning Modelle (z.B. Bild-/Spracherkennung)


Theoriebasierte Modellierung

Erstellung einer mathematischen Beschreibung mithilfe von Grundprinzipien

Beispiele: Physikalische Modelle (z.B. Wettervorhersage)

2. Feature Engineering

Daten- und theoriebasierte Modellierung



Quelle: Karpatne et al, IEEE T. Knowl. Data En. 29, 2318-2331, 2017

3. (Datengetriebene) Modellierung

3. Modellierung

Datengetriebene Modellierung

Wann ist maschinelles Lernen hilfreich?

- Es gibt Muster in den Daten
- Wir können diese Muster nicht (effizient) mathematisch beschreiben
- Wir haben Daten


Ist maschinelles Lernen hilfreich...

- ... zur Vorhersage des Wetters?
- ... zur Vorhersage der nächsten Zahl beim Roulette?
- ... zur Berechnung der Fläche eines Rechtecks?
- ... um ein Objekt in einem Foto zu finden?
- ... um Texte zu übersetzen?
- ... um Inhalte einer Streaming-Plattform zu empfehlen?

3. Modellierung

Supervised Learning (überwachtes Lernen)

- Input: $x \in X$ (Features)
- Output: $y \in Y$ (Label)
- (Unbekannte) Zielfunktion: $f(x) = y$
- Datensatz/Stichprobe: $(x_1, y_1), \dots, (x_n, y_n)$
- Ziel: Approximation von f basierend auf den Daten
 - Finde g sodass $g \approx f$



3. Modellierung

Supervised Learning (überwachtes Lernen)

Input: $x \in X$

Output: $y \in Y$

(Unbekannte) Zielfunktion: $f: X \rightarrow Y$

Klassifikation

Formal: Y ist **diskret**.

Informell: Wir versuchen die Klasse y vorherzusagen, zu der x gehört.

Modell: Klassifikator (*classifier*)

Ergebnis: Kategorie/Klasse

Regression

Formal: Y ist **stetig**.

Informell: Wir versuchen einen Wert y vorherzusagen, der von x abhängt.

Modell: Regressor (*regressor*)

Ergebnis: numerische Größe

Um welchen Vorhersagetyp handelt es sich bei den folgenden Problemen:

- Vorhersage von Nettomieten
- Vorhersage von epileptischen Anfällen
- Erkennung handgeschriebener Ziffern
- Vorhersage von Aktienkursen

3. Modellierung

Binäre Klassifikation

- Modell unterscheidet zwischen *zwei* Klassen
- Einfachstes Modell: Schwellwert-basierte Klassifikation

Beispiel

- Vorhersage des Geschlechts „Mann“ anhand von Daten des *National Health and Nutrition Examination Survey (NHANES, USA)* aus den Jahren 2009-2010.
Kennzahlen (summary statistics):

	Min	25%	Median	75%	Max
Age	241	418	584	748	959
Weight	32.4	67.2	78.8	92.6	218.2
Height	140	160	167	175	204
Leg Length	23.7	35.7	38.4	41	55.5
Arm Length	29.5	35.5	37.4	39.4	47.7
Arm Circumference	19.5	29.7	32.8	36.1	141.1
Waist	59.1	87.5	97.95	108.3	172

3. Modellierung

Schwellwert-basierte Klassifikation

- Feature Engineering: Suche nach Merkmalen, die sich zwischen Frauen und Männer unterscheiden
- Input: Körpergröße
- Modell:


$f: X \rightarrow \{0, 1\}$ Schwellwert

Frau Mann

$$f(x) = \begin{cases} 1, & \text{falls } x > \theta \\ 0, & \text{sonst} \end{cases}$$

Wie können wir den Schwellwert θ wählen?


- Unterschiedliche Werte liefern unterschiedliche Vorhersagen
- Welcher Wert ist gut?



3. Modellierung

Beurteilung eines Klassifikators

- P : Anzahl der Datenpunkte der vorherzusagenden Klasse (1 – Positiv)
- N : Anzahl der Datenpunkte der nicht vorherzusagenden Klasse (0 – Negativ)
- TP : Anzahl der korrekt vorhergesagten Positiven (True Positives)
- TN : Anzahl korrekt vorhergesagten Negativen (True Negatives)
- FP : Anzahl der Falsch-Positiven (False Positives)
- FN : Anzahl der Falsch-Negativen (False Negatives)



3. Modellierung

Beurteilung eines Klassifikators

		Vorhergesagte Klasse	
		Positiv	Negativ
Wahre Klasse	Positiv	True Positive (TP)	False Negative (FN)
	Negativ	False Positive (FP)	True Negative (TN)

➤ Was ist schlimmer? *FP* oder *FN*?

Smartphone Entsperren mit Fingerabdruck

		Vorhergesagte Klasse	
		Pos.	Neg.
Wahre Klasse	Pos.	TP: Akzeptiere Fingerabdruck des Besitzers	FN: Akzeptiere Fingerabdruck des Besitzers nicht
	Neg.	FP: Akzeptiere Fingerabdruck eines Angreifers	TN: Akzeptiere Fingerabdruck eines Angreifers nicht

FBI: Terroristenerkennung

		Vorhergesagte Klasse	
		Pos.	Neg.
Wahre Klasse	Pos.	TP: Erkenne Terrorist	FN: Identifiziere Terrorist als Zivilist
	Neg.	FP: Identifiziere Zivilist als Terrorist	TN: Erkenne Zivilist

➤ Es kommt darauf an!

3. Modellierung

Beurteilung eines Klassifikators

- Accuracy (Genauigkeit)

$$Acc = \frac{TP + TN}{TP + TN + FN + FP}$$

Anteil der richtig
klassifizierten
Datenpunkte

Nehmen Sie an, dass 50% der Daten der Klasse „Frau“ und die restlichen 50% der Klasse „Mann“ angehören. Diskutieren Sie folgende *Baseline Models* (Basismodelle):

1. Welche Accuracy erreichen Sie mit einem Modell, dass eine zufällige Klasse vorhersagt?
2. Welche Accuracy erhalten Sie mit einem Modell, das immer nur eine Klasse (z.B. „Frau“) vorhersagt?

3. Modellierung

Beurteilung eines Klassifikators

Baseline Models

- Einfache Modelle für die Einschätzung von Klassifikatoren
- „Wie gut ist mein Modell gegenüber einem einfachen, schnell erzeugten Baseline Model?“

- Angenommen 100 von 10000 Personen haben eine Krankheit
- Test A diagnostiziert 90 positiven Fälle korrekt, aber auch 5% der negativen Fälle als positiv (falsch positiv)
- Test B diagnostiziert alle Fälle als negativ
 1. Bestimmen Sie die Accuracy der Tests.
 2. Welcher Test ist besser?

	Test A	Test B
TP	90	0
TN	$0.95 \cdot 9900 = 9405$	9900
FP	$0.05 \cdot 9900 = 495$	0
FN	10	100
Accuracy	94.95%	99%

3. Modellierung

Beurteilung eines Klassifikators

Accuracy

- Einfaches Gütemaß
- Problematisch bei ungleich großen Klassen (*class imbalance*)
- Wir benötigen weitere Maße!

Precision

➤ $Precision = \frac{TP}{TP+FP}$

Anteil der Richtig-Positiven
an allen „positiv“
klassifizierten Datenpunkte

- Bestraft False Positives (*FP*)

Wie hoch ist die Precision für die Tests A und B?

	Test A	Test B
TP	90	0
TN	9405	9900
FP	495	0
FN	10	100
Precision	≈ 15.4%	—

3. Modellierung

Beurteilung eines Klassifikators

Recall (auch TPR – True Positive Rate)

$$\text{Recall} = \frac{TP}{TP+FN} = \frac{TP}{P}$$

- Bestraft False Negatives (FN)

Anteil der Richtig-
Positiven an allen
Positiven

Wie hoch ist der Recall für die Tests A und B?

Oft werden Precision und Recall zusammengefasst:

- F_1 -Score

- Harmonisches Mittel aus Precision und Recall

$$F_1 = \left(\frac{\text{Recall}^{-1} + \text{Precision}^{-1}}{2} \right)^{-1} = 2 \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \in [0, 1]$$

- Je größer der F_1 -Score, desto besser der Klassifikator

	Test A	Test B
TP	90	0
TN	9405	9900
FP	495	0
FN	10	100
Recall	90%	0%
Precision	≈ 15.4%	–
F_1 -Score	≈ 26.3%	–

3. Modellierung

Beurteilung eines Klassifikators


➤ $Precision = \frac{TP}{TP+FP}$

➤ $Recall = \frac{TP}{TP+FN} = \frac{TP}{P}$

- Oft kann mit einstellbaren (freien) Parametern zwischen True Positive Rate (TPR) und False Positive Rate (FPR) abgewogen werden

$$TPR = \frac{TP}{P}$$


$$FPR = \frac{FP}{N}$$



3. Modellierung

Beurteilung eines Klassifikators

- Receiver Operation Characteristic (ROC) Kurve
 - TPR vs. FPR (Variation von freiem Parameter)



- ROC Kurve beschreibt wie gut trennbar die Verteilungen sind


3. Modellierung

Receiver Operation Characteristic (ROC)

- Welche Kurve erhalten wir bei identischen Verteilungen, d.h. wenn die Klasse nicht unterscheidbar sind?
 - Diagonale (entspricht Zufallsvorhersage)
- Welcher Punkt auf der ROC Kurve entspricht dem besten Klassifikator?
 - Grundsätzlich: Abwägung zwischen TPR und FPR
 - Punkt mit größter Distanz zur Diagonalen

Youden Index

$J = TPR - FPR$ wird maximal
an Punkt mit maximaler Distanz




3. Modellierung

Receiver Operation Characteristic (ROC)

- Wahl des Schwellwerts über Youdens J

$$\tilde{\theta} = \arg \max_{\theta} J(\theta)$$


- Je nach Anwendung ggf. anderer Schwellwert
 - Smartphone entsperren: FP schlechter
 - Terroristenerkennung: FN schlechter



3. Modellierung

Receiver Operation Characteristic (ROC)

- Die ROC-Kurve ist eine Funktion
- Können wir die Funktion in einem einzelnen Wert zusammenfassen, um zwei Klassifikatoren zu vergleichen?
 - Ja! → Fläche unter der Kurve (AUC - Area Under Curve)
 - Aber: Wir verlieren Informationen
- Die AUC (Area Under Curve) variiert zwischen 0.5 (zufällige Vorhersage) und 1 (perfekte Vorhersage)



3. Modellierung

Beurteilung eines Klassifikators

Es gibt eine Vielzahl von Gütemaßen

$$\text{➤ Accuracy} = \frac{TP+TN}{TP+TN+FP+FN}$$

$$\text{➤ Precision} = \frac{TP}{TP+FP}$$

$$\text{➤ Recall} = \frac{TP}{TP+FN} = \frac{TP}{P} \quad (\text{auch Sensitivität oder TPR – True Positive Rate})$$

$$\text{➤ Specificity} = \frac{TN}{TN+FP} = \frac{TN}{N} \quad (\text{auch Spezifität oder TNR – True Negative Rate})$$

$$\text{➤ } F_1 = 2 \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Alle diese Gütemaße fassen Informationen zusammen, nur die Konfusionsmatrix (confusion matrix) zeigt das gesamte Bild:

		Vorhersage	
		Pos.	Neg.
Wahre Klasse	Pos.	TP	FN
	Neg.	FP	TN

3. Modellierung

Beurteilung eines Klassifikators

Bisher: Binäre Klassifikation

- Zwei Klassen
- Einfachstes Modell: Schwellwert-basiert

Jetzt: mehr als zwei Klassen

- Einfachstes Modell: k -nächste Nachbarn (kNN - k nearest neighbors)
- Accuracy und confusion matrix lassen sich direkt verallgemeinern

$$\text{Acc} = \frac{\text{Anz. korrekt klassifiziert}}{\text{Stichprobengröße}} = \frac{\text{tr}(cm)}{\text{sum}(cm)}$$

		Vorhersage			
		Klasse 1	Klasse 2	...	Klasse n
Wahre Klasse	Klasse 1	c_{11}	c_{12}	...	c_{1n}
	Klasse 2	c_{21}	c_{22}	...	c_{2n}
	...	...	...	...	...
	Klasse n	c_{n1}	c_{n2}	...	c_{nn}

3. Modellierung

Code in topic11_modelling/
measuring_quality.py

Beurteilung eines Klassifikators – Übung

1. Gegeben sei die folgende Konfusionsmatrix eines binären Klassifizierers. Berechnen Sie Accuracy, Precision und Recall.

		Vorhersage	
		Klasse 1	Klasse 2
Wahre Klasse	Klasse 1	100	50
	Klasse 2	20	30

2. Gegeben sei die folgende Konfusionsmatrix eines Klassifizierers. Berechnen Sie Accuracy.

		Vorhersage			
		Klasse 1	Klasse 2	Klasse 3	Klasse 4
Wahre Klasse	Klasse 1	65	13	5	17
	Klasse 2	4	90	3	3
	Klasse 3	23	5	69	3
	Klasse 4	4	7	3	86

3. Modellierung

***k*-nächste Nachbarn**

- Sie wollen die PIN eines Handys knacken
- Sie haben noch einen Versuch
- Was sind übliche PINs?
 - Zahlenfolgen
 - 1-2-3-4
 - 1-1-1-1
 - Muster
 - 1-3-7-9
 - 1-4-7-8
 - Jahreszahlen
 - 1-9-0-0
 - ...

Welche Zahl
wählen Sie?



Quelle: <https://versus.com/en/nokia-3310>

3. Modellierung

k -nächste Nachbarn

Profifußball im Ruhrgebiet (Saison 2024/2025, Änderungen möglich)

- Bundesliga
 - Bochum 1848
 - Dortmund 1909
- 2. Bundesliga
 - Schalke 1904
- 3. Liga
 - Essen 1907
- *Regionalliga West*
 - *Duisburg 1902*
 - *Oberhausen 1904*



Welchen Verein unterstützt man in Städten ohne eigenen Verein?

Quelle: <https://www.rvr.ruhr/politik-regionalverband/staedte-kreise/>, Wikipedia

3. Modellierung

k -nächste Nachbarn

Welchen Verein unterstützt man in Herne?



Quelle: <https://www.pinterest.de/pin/643733340505447883>, Wikipedia

3. Modellierung

***k*-nächste Nachbarn**

Von welchem Verein ist eine uns unbekannte Person Fan?

- Welchen Verein unterstützen die Nachbarn:
 - Der nächste Nachbar: Dortmund
 - Die nächsten 4 Nachbarn: Bochum
- Was ist ein guter Tipp?
- Systematisches Vorgehen:
 - *k*-nearest-neighbors



3. Modellierung

***k*-nächste Nachbarn**

Gegeben:

- Datensatz $(X_1, y_1), (X_2, y_2), \dots (X_n, y_n)$
- Anzahl Nachbarn k
- Input X

Gesucht:

- Zielgröße y



k-nearest neighbors (*k*-nächste Nachbarn Algorithmus)

1. Berechne für jeden Punkt $X_1, X_2, \dots, X_n$ den Abstand zu X
2. Suche aus dem Datensatz die k nächsten Punkte um X
3. Bestimme häufigste Klasse y der Nachbarn

3. Modellierung

k -nächste Nachbarn

Gegeben:

- Datensatz: s. Karte
- Anzahl Nachbarn $k = 3$
- Input X (entspricht „?“)

Gesucht:

- Zielgröße y (Fußballverein)



```
>>> y = VfL Bochum
```

Auf welcher Annahme basiert der kNN-Algorithmus?

- „Nahe“ Punkte haben ähnliche Eigenschaften

3. Modellierung

***k*-nächste Nachbarn**

Wie erstellt man ein kNN-Modell in Python?

```
from sklearn.neighbors import KNeighborsClassifier  
  
model = KNeighborsClassifier(*model_args, **model_kwargs)  
model.fit(X_train, y_train)  
prediction = model.predict(X_test)
```

- kNN ist ein „Lazy Learner“: Training besteht aus Speichern des Datensatzes

Feature Engineering & Datengetriebene Modelle

Rückblick

- Was ist das Ziel des Feature Engineerings?
- Woher wissen wir, wie Daten transformiert werden sollten?
- Was ist der Unterschied zwischen datengetriebener und theoriebasierter Modellierung?
- Wann ist maschinelles Lernen hilfreich?
- Wie kann supervised learning (mathematisch) beschrieben werden?
- Was ist der Unterschied zwischen Klassifikation und Regression?
- Wofür sind Baseline Modelle hilfreich?
- Was ist bei einem binären Klassifikator schlimmer: False Positives oder False Negatives?
- Was ist die Accuracy eines Klassifikators?
- Wofür brauchen wir Precision und Recall?
 - Wie sind sie definiert?

Feature Engineering & Datengetriebene Modelle

Rückblick

- Wie erhalten wir eine ROC Kurve?
- Wie erhalten wir aus einer ROC Kurve den "besten" Klassifikator?
- Welche Größe fasst die ROC Kurve in einer Zahl zusammen?
- Was ist eine Konfusionsmatrix?
- Wie funktioniert der k-nächste Nachbarn Algorithmus?
- Auf welcher impliziten Annahme basiert der kNN-Algorithmus?